UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Aplicação de Técnicas de Aprendizado de Máquina na Predição de Falhas em Motores Elétricos

Vítor Fernando Rinaldini

Monografia - MBA em Inteligência Artificial e Big Data

ICMC USP SÃO CARLOS

Vítor Fernando Rinaldini

Aplicação de Técnicas de Aprendizado de Máquina na Predição de Falhas em Motores Elétricos

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientador: Prof. Dr. Antonio Fernando Lavareda Jacob Junior

Versão original

São Carlos

2026

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

Rinaldini, Vitor
R578a Aplicação de Técnicas de Aprendizado de Máquina na Predição de Falhas em Motores Elétricos / Vitor Rinaldini; orientador Antonio Fernando Lavareda Jacob Junior Junior. -- São Carlos, 2026.
50 p.

Trabalho de conclusão de curso (MBA em Inteligência Artificial e Big Data) -- Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026.

1. Aprendizado de Máquina para Classificação de Falhas. 2. Processamento e Extração de Características. 3. Radar de Onda Contínua. 4. Monitoramento de Motores Elétricos. 5. Manutenção Preditiva. I. Junior, Antonio Fernando Lavareda Jacob Junior, orient. II. Título.

Bibliotecários responsáveis pela estrutura de catalogação da publicação de acordo com a AACR2:
Gláucia Maria Saia Cristianini - CRB - 8/4938
Juliana de Souza Moraes - CRB - 8/6176

RESUMO

RINALDINI, V. **Aplicação de Técnicas de Aprendizado de Máquina na Predição de Falhas em Motores Elétricos**. 2026. 57 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Um dos custos mais relevantes do setor industrial está relacionado à manutenção de equipamentos, especialmente à manutenção corretiva ou reativa. A adoção de uma abordagem baseada em manutenções não planejadas pode resultar em perdas de produtividade, necessidade de fabricação emergencial de peças e contratação de mão de obra para o restabelecimento dos equipamentos. Nesse contexto, a manutenção preditiva apresenta-se como uma alternativa, permitindo identificar possíveis falhas antes que ocorram e realizar intervenções somente quando necessário. Visando contribuir para essa abordagem, este trabalho investiga a aplicação de métodos de *machine learning* na predição de falhas em motores elétricos, importantes equipamentos utilizados na geração de energia motriz no setor industrial. Para isso, é criado um *dataset* a partir de dados obtidos por meio de um radar de onda contínua de 10 kHz de taxa de amostragem, cujos sinais são processados e submetidos a diferentes modelos de aprendizado supervisionado, incluindo o Naive Bayes Gaussiano, a Árvore de Decisão, o *Random Forest*, o *K-Nearest Neighbors* (KNN) e o *Multilayer Perceptron*. Ao final, os modelos são comparados quanto ao seu desempenho na classificação das condições de funcionamento do motor, sendo o KNN o algoritmo que apresentou o maior desempenho, permitindo analisar a aplicabilidade das técnicas utilizadas na identificação de falhas.

Palavras-chave: motores elétricos; radar de onda contínua; aprendizado de máquina; extração de características; classificação de falhas; aprendizado supervisionado.

ABSTRACT

RINALDINI, V. **Application of Machine Learning Techniques for Failure Prediction in Electric Motors**. 2026. 57 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

One of the most significant costs in the industrial sector is associated with equipment maintenance, particularly corrective or reactive maintenance. The adoption of an unplanned maintenance approach can result in productivity losses, the need for emergency manufacturing of parts, and the hiring of labor to restore equipment operation. In this context, predictive maintenance emerges as an alternative, enabling potential failures to be identified before they occur and interventions to be performed only when necessary. Aiming to contribute to this approach, this study investigates the application of machine learning methods for the prediction of failures in electric motors, which are important equipment used to provide mechanical power in the industrial sector. To this end, a dataset is created from data obtained using a continuous-wave radar with a sampling rate of 10 kHz. The signals are processed and submitted to different supervised learning models, including Gaussian Naive Bayes, Decision Tree, Random Forest, K-Nearest Neighbors (KNN), and Multilayer Perceptron. Finally, the models are compared based on their performance in classifying the operating conditions of the motor, with KNN achieving the highest performance, thereby enabling an analysis of the applicability of the techniques used for fault identification.

Keywords: electric motors; continuous-wave radar; machine learning; feature extraction; failure classification; supervised learning.

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Motivação 11
1.2 Contexto 11
1.3 Problema 12
1.4 Objetivos 12
1.5 Estrutura 13

2 FUNDAMENTAÇÃO TEÓRICA 15
2.1 Motores Elétricos 15
2.2 Principais Falhas em Motores Elétricos 17
2.2.1 Defeitos no Rolamento 17
2.2.2 Falhas no Estator ou Armadura 18
2.2.3 Problemas nas Barras do Rotor 18
2.2.4 Desbalanceamento 19
2.2.5 Desalinhamento (Vertical e Horizontal) 19
2.3 Tecnologias de Medição de Vibração 19
2.3.1 Sensores Fixados — Acelerômetros 20
2.3.2 Sensores Sonoros 20
2.3.3 Sensores por Câmera 20
2.3.4 Sensores por Radar de Onda Contínua 21
2.4 Técnicas Preditivas com Inteligência Artificial 22
2.4.1 Transformada de Fourier 22
2.4.2 Modelos de classificação 22

3 METODOLOGIA 23
3.1 Banco de dados utilizado 23
3.1.1 Obtenção dos dados 24
3.1.2 Armazenamento dos dados 24
3.1.3 Segmentação dos dados 25
3.2 Extração de *Features* 26
3.2.1 Domínio do Tempo 26
3.2.2 Domínio da Frequência 29
3.3 Preprocessamento dos Dados 32
3.3.1 Analise Exploratória 32
3.3.2 Balanceamento 34
3.3.3 Normalização 34

3.4 Classificação **34**

4 AVALIAÇÃO EXPERIMENTAL **35**
4.1 Análise Exploratória das *features* **35**
4.1.1 Remoção de *Features* Temporaris 35
4.1.2 Remoção de *Features* Espectrais 37
4.1.3 Remoção de *Features* de Alta Correlação 38
4.2 Resultados da Classificação **40**
4.2.1 Classificador - Naive Bayes Gaussiano 41
4.2.2 Classificador - Árvore de Decisão 42
4.2.3 Classificador - *Random Forest* 43
4.2.4 Classificador - *K-Nearest Neighbors* 45
4.2.5 Classificador - Multilayer Perceptron 47

5 CONCLUSÕES **49**

REFERÊNCIAS BIBLIOGRÁFICAS **51**

APÊNDICES **53**

APÊNDICE A – APÊNDICE(S) **55**

1 INTRODUÇÃO

1.1 Motivação

Um dos grandes objetivos dos trabalhadores administrativos do setor industrial é buscar oportunidades de redução de custo. Há diversas formas de atuação para atingir essa meta e, primeiramente, faz-se necessário analisar as fontes de custo para identificar a maneira mais eficiente de cumprir esse objetivo. Segundo Thonmas e Weiss em um estudo envolvendo diversas empresas norte americanas, os custos decorrentes de perdas relacionadas à manutenção representam a parcela mais significativa, correspondendo a um valor estimado de aproximadamente US$ 222 bilhões por ano. (Thomas; Weiss, 2021)

Dessa forma, buscar novas abordagens para tratar os problemas do setor de Manutenção Industrial é um caminho eficiente para alcançar uma redução de custo significativa no valor agregado do processo produtivo da empresa.

1.2 Contexto

A redução de custos relacionados ao reparo de máquinas é um dos principais desafios da manutenção industrial. Para compreender esses valores, é essencial analisar as diferentes formas de atuação da manutenção, que pode ser classificada em corretiva (ou reativa), preventiva e preditiva.

A manutenção corretiva ocorre quando a intervenção é realizada após a ocorrência de uma falha. Embora essa estratégia possa ser adequada para determinados equipamentos e modos de falha, a ocorrência não planejada de falhas pode resultar em paradas inesperadas, perda de disponibilidade e aumento dos custos associados à manutenção e à produção. Por sua vez, a manutenção preventiva baseia-se na realização de intervenções em intervalos previamente estabelecidos, buscando reduzir a probabilidade de falha. Entretanto, essa abordagem pode resultar na substituição de componentes antes do término de sua vida útil. Já a manutenção preditiva utiliza informações sobre a condição do equipamento para determinar a necessidade e o momento mais adequado para uma intervenção, permitindo reduzir falhas inesperadas e otimizar os intervalos entre reparos. (Mobley, 2002)

A manutenção preditiva traz várias vantagens em relação à manutenção reativa, uma vez que a indústria consegue se planejar para realizar intervenções nas máquinas sem impactar os operadores com paradas não planejadas e sem interromper as atividades programadas da equipe de manutenção. Há um conceito interessante na ramo da Manutenção Industrial chamada Curva PF, do inglês *Potential Failure Curve*, que exemplifica como uma falha se comporta em realçao ao tempo, conforme a figura 1. Ao analisá-la, podemos inferir que uma falha começa muito antes de mostrar sinais perceptíveis para os operadores e em

alguns casos esse é o melhor momento para a manutenção atuar na correção do problema (TRACTIAN, 2026). Para complementar, o estudo realizado em 2021 por Thomas e Weiss, verificou-se que empresas que dependiam menos da manutenção corretiva e utilizavam com maior frequência estratégias preventivas e preditivas apresentaram 52,7% menos tempo de parada não planejada e 78,5% menos defeitos, resultando, consequentemente, em maior disponibilidade de seus equipamentos. (Thomas; Weiss, 2021)

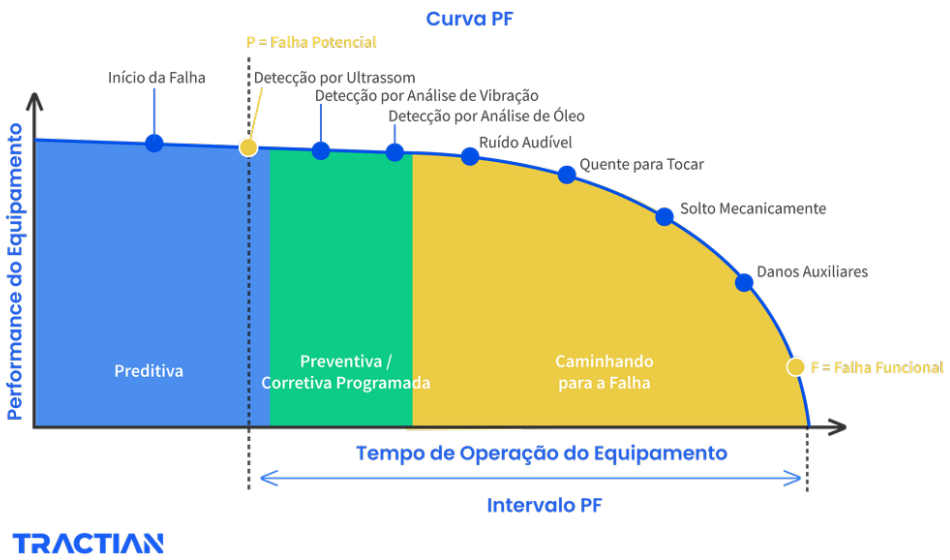


Figura 1 – Curva PF (Falha em Potencial). Adaptado de (TRACTIAN, 2026)

1.3 Problema

Tendo em vista esse contexto, existem diversas oportunidades para a aplicação de técnicas avançadas de manutenção preditiva, de forma a minimizar as paradas não planejadas. Este trabalho foca especificamente nas análises relacionadas à vibração e ao ruído emitidos por motores elétricos industriais. Em muitos casos, falhas em estágio avançado produzem vibrações tão intensas que podem ser facilmente percebidas pelos operadores, indicando a iminência de uma falha grave ou quebra do equipamento.

O estudo será baseado no uso de radar para a obtenção dos dados. A justificativa para a escolha desse instrumento é simples: sua utilização dispensa a desmontagem da carcaça do equipamento e permite a realização de medições sem contato direto, reduzindo a exposição do manutentor a riscos de acidentes durante a inspeção.

1.4 Objetivos

Este trabalho tem como objetivo estudar o desempenho da aplicação de técnicas de *machine learning* em dados obtidos por meio de um dispositivo de radar de onda contínua,

visando à manutenção preditiva do principal componente rotativo do setor industrial: o motor elétrico. Para atingir esse objetivo, será utilizado o mesmo conjunto de dados obtido no artigo (Acar; Acar; Kilic, 2026), o qual será descrito em uma seção específica. Para atingir esta meta, o estudo será conduzido através das abordagens a seguir:

- **Extração de caracteristicas:** Extrair características representativas dos sinais de vibração obtidos por radar de onda contínua, considerando diferentes janelas temporais;
- **Construção de modelos preditivos:** Desenvolver e ajustar modelos de *machine learning*, buscando reduzir a ocorrência de underfitting e overfitting durante o processo de classificação;
- **Comparação dos modelos:** Comparar o desempenho dos modelos de classificação utilizando a métrica de acurácia, visando identificar as diferenças de desempenho entre os métodos avaliados.

1.5 Estrutura

O trabalho está estruturado da seguinte forma: primeiramente, no capítulo de introdução, é apresentada a problemática abordada neste estudo, destacando-se a relevância do tema e as contribuições que a pesquisa pode proporcionar para a área de interesse.

Em seguida, é apresentada a fundamentação teórica, na qual são abordados os principais componentes do motor elétrico industrial, as formas de medição das grandezas fundamentais para a realização deste estudo e algumas das técnicas utilizadas nas etapas subsequentes de obtenção e processamento dos dados.

No terceiro capítulo, é apresentada a metodologia utilizada, contemplando a origem do banco de dados empregado no estudo, bem como as etapas de processamento dos dados e classificação dos sinais.

Por fim, no quarto capítulo, é realizada uma comparação entre os diferentes métodos de Inteligência Artificial aplicados ao problema estudado, evidenciando suas respectivas métricas de desempenho, condições de aplicação e demais observações pertinentes.

2 FUNDAMENTAÇÃO TEÓRICA

Para resolver um dos grandes problemas da indústria moderna, é necessário, primeiramente, compreender o funcionamento dos componentes mecânicos e elétricos que estão contidos nos motores elétricos, como os rolamentos, as barras do rotor, o estator e em seguida, entender quais são os módulos de falhas e como cada um se comporta em relação a operação nominal do equipamento mecânico. É através deste princípio que pode-se elaborar maneiras de mensurar e utilizar técnicas de analise dos dados obtivos e, por fim, realizar a classificação.

2.1 Motores Elétricos

Existem diversos tipos de motores, classificados de acordo com a forma de energia convertida em movimento, como motores de combustão, híbridos e a vapor (Castro, 2024). Neste trabalho, será realizado um estudo focado em motores elétricos aplicados à indústria moderna. O motor elétrico industrial é um dispositivo capaz de transformar energia elétrica em energia mecânica (Santos, 2024). Em outras palavras, é responsável por gerar movimento em máquinas e acionar mecanismos utilizados na transformação de matérias-primas em bens de consumo, sejam eles duráveis, como eletrodomésticos, ou não duráveis, como alimentos embalados.

As principais partes de um motor elétrico são apresentadas a seguir, conforme (Cordeiro, 2022). A Figura 2 ilustra a disposição e a interação entre esses componentes.

- **Estator:** é a parte estacionária do motor, constituída principalmente pelo núcleo magnético e pelos enrolamentos elétricos. Quando energizados, os enrolamentos produzem um campo magnético responsável pela interação eletromagnética que possibilita a conversão de energia elétrica em energia mecânica;

- **Rolamentos:** são elementos responsáveis por apoiar o eixo do rotor e permitir sua rotação, reduzindo o atrito e as perdas mecânicas durante o funcionamento do motor;

- **Rotor:** é a parte móvel do motor, localizada no interior do estator. Sua construção depende do princípio de funcionamento do motor e pode incluir barras condutoras, enrolamentos ou ímãs permanentes;

- **Mancais:** são estruturas responsáveis pelo suporte e posicionamento do eixo do rotor, contribuindo para a manutenção do alinhamento adequado entre os componentes rotativos e estacionários;

- **Carcaça:** é responsável por proteger os componentes internos e fornecer suporte estrutural ao motor e ao estator. Sua construção pode ser projetada para suportar condições adversas presentes em ambientes industriais, oferecendo proteção contra poeira, umidade e outros contaminantes.

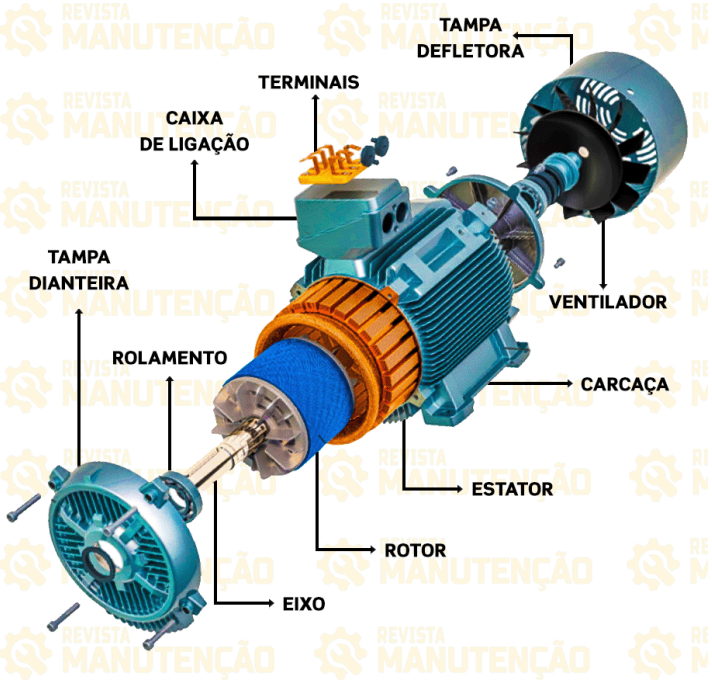


Figura 2 – Partes de um motor elétrico. Retirado de (Cordeiro, 2022)

Durante a operação do motor, os mancais e rolamentos são responsáveis por manter o eixo do rotor adequadamente apoiado e alinhado, permitindo sua rotação com baixos níveis de atrito. O desgaste desses componentes é um dos fatores que podem comprometer o funcionamento do motor ao longo do tempo, podendo resultar em vibrações, aumento da temperatura, ruídos e, em casos mais severos, falhas do equipamento. Quando a intervenção ocorre somente após a ocorrência de uma falha, caracteriza-se uma manutenção corretiva (Service, 2022).

A inspeção e a manutenção de um motor elétrico podem exigir profissionais especializados e resultar em custos elevados, principalmente quando envolvem a parada da máquina, a desmontagem do equipamento e o encaminhamento para reparo externo. Nesse contexto, torna-se importante o desenvolvimento de métodos capazes de monitorar, de forma não invasiva, variáveis elétricas e mecânicas associadas ao funcionamento do motor, possibilitando a identificação antecipada de alterações em seu comportamento e a realização de intervenções antes da ocorrência de falhas mais graves.

Nas próximas seções, serão apresentados os principais modos de falha associados aos componentes dos motores elétricos, bem como técnicas utilizadas para a detecção preditiva de anomalias.

2.2 Principais Falhas em Motores Elétricos

2.2.1 Defeitos no Rolamento

Os rolamentos de esferas e de elementos rolantes são amplamente utilizados em máquinas elétricas e são constituídos por anéis interno e externo (veja a figura 3), entre os quais se encontram os elementos rolantes. Mesmo em condições normais de operação, podem ocorrer falhas decorrentes da fadiga do material, causando aumento dos níveis de vibração e ruído. Um exemplo é o *flaking* ou *spalling*, caracterizado pelo desprendimento de partículas da superfície do rolamento. (Nandi; Toliyat; Li, 2005)

Além da fadiga, fatores como vibração, excentricidade e correntes elétricas, assim como contaminação, corrosão, lubrificação inadequada e erros de instalação, podem acelerar a degradação dos rolamentos. Estima-se que aproximadamente 40% a 50% das falhas em motores elétricos estejam relacionadas a esses componentes. (Nandi; Toliyat; Li, 2005)

Os defeitos em rolamentos de esferas podem ser classificados de acordo com a região afetada: pista externa, pista interna, elementos rolantes ou gaiola [1]. Cada tipo de defeito apresenta frequências características de vibração, que podem ser utilizadas para sua identificação e diagnóstico por meio de técnicas de monitoramento e manutenção preditiva. Os defeitos relacionados a esse componente são proporcionais a velocidade de rotação do rotor e as frequências em que respectivamente ocorrem podem ser calculados pelas equações a seguir, retiradas do atigo (Nandi; Toliyat; Li, 2005). Nelas, f_v significa frequência de rotação, N é o numero de esferas, b_d e d_p são o diâmetro da esfera e o diâmetro primitivo das esfreras, e β é o ângulo de contato das esferas com a pista.

- $f_v[Hz] = \frac{N}{2} f_r[1 - b_d cos(\beta)/d_p]$: para um defeito na pista externa do rolamento;
- $f_v[Hz] = \frac{N}{2} f_r[1 + b_d cos(\beta)/d_p]$: para um defeito na pista interna do rolamento;
- $f_v[Hz] = b_d \frac{f_r}{2} b_d 1 - [b_d cos(\beta)/d_p]^2$: para um defeito de esfera;
- $f_v[Hz] = \frac{f_r}{2}[1 - b_d cos(\beta)/d_p]$: para um defeito na gaiola.

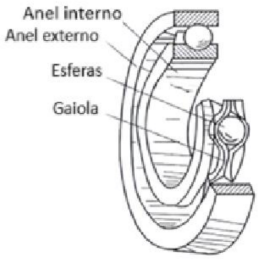


Figura 3 – Partes de um rolamento. Adaptado de (Luna *et al.*, 2025)

2.2.2 Falhas no Estator ou Armadura

Essas falhas estão principalmente relacionadas à deterioração do isolamento elétrico e são conhecidas como falhas fase-terra ou fase-fase. Geralmente, iniciam-se como falhas entre espiras que, quando não detectadas, podem evoluir para defeitos mais graves. Aproximadamente 30%–40% das falhas em motores de indução estão relacionadas a essa categoria. (Nandi; Toliyat; Li, 2005)

Entre as principais causas estão temperaturas elevadas no núcleo ou nos enrolamentos, folgas nas laminações e ranhuras, fixação inadequada dos enrolamentos, contaminação por óleo, umidade e sujeira, esforços durante curtos-circuitos ou partidas, descargas elétricas e vazamentos no sistema de refrigeração. (Nandi; Toliyat; Li, 2005)

Para a detecção dessas falhas, especialmente em motores e geradores de alta tensão, os ensaios de descarga parcial (DP) apresentam resultados confiáveis. (Nandi; Toliyat; Li, 2005). Os componentes de frequência a detectar no componente de fluxo axial são dados pela equação a seguir, onde p é o numerode polos, f é a frequencia principal, $k = 1, 3$, $n = 1, 2, 3, ..., (2p - 1)$ e s é o escorregamento.

$$f_s = (k \pm n(1 - s)/p)f \tag{2.1}$$

2.2.3 Problemas nas Barras do Rotor

As falhas nas barras do rotor e nos anéis de curto-circuito podem ser provocadas por diferentes tipos de esforços, incluindo tensões térmicas, magnéticas, residuais, dinâmicas, ambientais e mecânicas. Entre os principais fatores estão sobrecargas, forças eletromagnéticas, problemas de fabricação, forças centrífugas, contaminação e falhas nos rolamentos.

A detecção de barras quebradas pode ser realizada por meio da análise espectral da corrente elétrica do motor (MCSA). Essa técnica utiliza principalmente a análise das componentes de frequência laterais próximas à frequência fundamental para identificar esse tipo de falha. Para classificar um rolamento que está com esse tipo de problema, são analisadas as frequências laterais da frequência fundamental. Vale, salientar que o essas frequências sofrem influência da carga do rotor e da oscilação da velocidade de rotação. De uma forma geral, a equação dessas frequências está denotada a seguir, onde f_b é a frquencia onde detectamos a barra quebrada, $\frac{k}{p} = 1, 3, 5, ...$

$$f_b = [\frac{k}{p}(1 - s) \pm s]f \tag{2.2}$$

2.2.4 Desbalanceamento

O desbalanceamento ocorre quando o centro de massa de um elemento rotativo não coincide com seu centro de rotação. Embora o balanceamento possa reduzir esse efeito, um rotor perfeitamente balanceado é praticamente impossível de ser obtido devido a fatores como tolerâncias de fabricação, distribuição não uniforme da densidade do material, porosidades e alterações de massa durante a operação. (Jalan; Mohanty, 2009)

Essa condição gera forças periódicas no sistema rotativo, podendo aumentar os níveis de vibração e provocar esforços adicionais nos componentes.

2.2.5 Desalinhamento (Vertical e Horizontal)

O desalinhamento de eixos ocorre quando os eixos da máquina motriz e da máquina acionada não permanecem perfeitamente alinhados. Na prática, essa condição é praticamente inevitável devido a fatores como dilatação térmica, deformações estruturais, movimentação da fundação e esforços provenientes das tubulações. (Jalan; Mohanty, 2009)

Essa condição gera forças e momentos no acoplamento, aumentando os níveis de vibração e podendo provocar esforços adicionais em componentes como eixos e mancais. No domínio da frequência, o desalinhamento é normalmente identificado pela presença de harmônicos da velocidade de rotação, com destaque para a componente em 2 vezes a frequência de rotação, além de seus múltiplos, como 4 vezes.

2.3 Tecnologias de Medição de Vibração

Os motores elétricos apresentam diferentes formas de indicar o surgimento de falhas. Anomalias na rotação podem gerar variações de torque, que podem ser inferidas por meio de grandezas elétricas, como corrente, tensão e potência ou ainda, através do ruído emitido pelo movimento de seus componentes.

A coleta dessas variáveis pode ser realizada por diferentes métodos, incluindo o monitoramento de grandezas elétricas e o emprego de sensores capazes de medir grandezas mecânicas associadas ao funcionamento dos motores, como vibração e deformação. Entre essas tecnologias, destacam-se os sensores de vibração e os *strain gauges*, que podem ser utilizados para monitorar deformações mecânicas em componentes do sistema (TRACTIAN, 2023). Além disso, microfones podem ser empregados para o monitoramento acústico, uma vez que determinadas falhas, especialmente em rolamentos, podem provocar alterações nos níveis e nas características do ruído emitido pelo equipamento. Esses ruídos podem, em alguns casos, ser identificados por profissionais experientes durante inspeções realizadas no equipamento. Neste tópico, serão apresentadas as principais tecnologias utilizadas para a aquisição dessas variáveis e suas respectivas aplicações no monitoramento e diagnóstico de falhas em motores elétricos.

2.3.1 Sensores Fixados — Acelerômetros

O acelerômetro é um dispositivo eletrônico utilizado para medir a aceleração e detectar variações de movimento, vibração e inclinação. Seu funcionamento permite identificar alterações na velocidade de um objeto, incluindo efeitos provocados pela gravidade. Dessa forma, esses sensores podem ser empregados para determinar orientação, detectar impactos e monitorar vibrações. Devido à sua versatilidade, são amplamente utilizados em aplicações industriais, automotivas, robóticas, médicas e aeroespaciais.

Há diversos tipos de acelerômetros e cada um possui um funcionamento diferente. Acelerômetros capacitivos medem a aceleração detectando mudanças na capacitância à medida que a massa de prova interna se move (Figura 4a); Os acelerômetros piezoelétricos utilizam materiais especiais que geram uma carga elétrica quando são comprimidos ou esticados por vibração, permitindo-lhes medir a aceleração com alta sensibilidade (Figura 4b); Acelerômetros piezoresistivos medem a aceleração detectando mudanças na resistência elétrica quando o elemento sensor é tensionado por movimento ou impacto (Figura 4c); entre outros (ALLELCO, 2025). Eles precisam ser fixados na carcaça do componente a ser estudo e, portanto, requerem uma manutenção mais invasiva para sua utilização.



(a) Capacitivo (b) Piezoelétrico (c) Piezoresistivo

Figura 4 – Tipos de acelerômetros fixos. Adaptado de (ALLELCO, 2025)

2.3.2 Sensores Sonoros

A Emissão Acústica, conforme explicado por *Kundu* (Kundu, 2024), consiste na propagação de ondas de tensão elástica transitórias através de uma estrutura, originadas pela liberação rápida de energia causada por alterações internas no material ou pelo contato entre asperezas durante a aplicação de cargas.

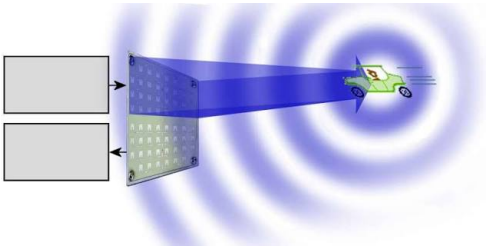
2.3.3 Sensores por Câmera

Nessa abordagem, uma câmera registra o movimento do objeto, enquanto técnicas de processamento de imagens são utilizadas para extrair as informações de vibração. Entre os métodos desenvolvidos, destaca-se o fluxo óptico baseado na fase do vídeo, que permite identificar movimentos a partir das variações de fase das imagens. Posteriormente, essa abordagem foi combinada com técnicas de amplificação de movimento, possibilitando a análise de frequências de ressonância, modos de deformação e deslocamentos de estruturas (Peng *et al.*, 2023).

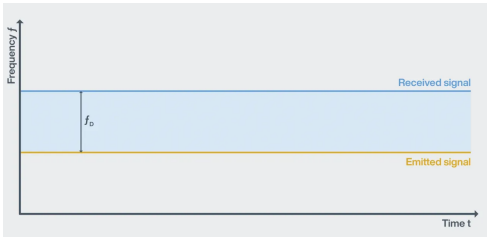
2.3.4 Sensores por Radar de Onda Contínua

O radar de onda contínua não modulada, também denominado radar CW ou Doppler, transmite continuamente ondas eletromagnéticas em uma frequência constante. A partir da análise do deslocamento Doppler presente no sinal refletido, é possível identificar objetos em movimento e estimar sua velocidade na direção de propagação do sinal. Entretanto, esse tipo de radar não permite determinar diretamente a distância ou a posição do objeto com precisão adequada, sendo necessárias técnicas adicionais para essa finalidade (Pepperl+Fuchs, 2026).

O princípio de funcionamento baseia-se na alteração da frequência da onda eletromagnética após sua reflexão em um objeto em movimento. Dependendo da direção do movimento, a frequência do sinal refletido pode sofrer aumento ou redução. Esse sinal é então comparado com a onda originalmente transmitida, e a diferença entre as frequências permite determinar informações relacionadas ao movimento e à velocidade do objeto. A velocidade medida depende da componente do movimento na direção de observação do radar, sendo necessário considerar o ângulo entre o deslocamento do objeto e o sensor.



(a) Esquema de funcionamento do radar de onda contínua.



(b) Diferença entre o sinal transmitido e o recebido para um movimento uniforme;

Figura 5 – Funcionamento de um radar de onda contínua. Adaptado de (Pepperl+Fuchs, 2026)

A figura 5 evidencia o funcionamento do disposiivo para um movimento uniforme, onde há uma diferença de tempo entre o sinal transmitido e o sinal recebido de após reflexão no objeto de estudo. Embora acelerômetros e extensômetros sejam amplamente utilizados, sua aplicação pode ser limitada pela dificuldade de instalação, pelo acréscimo de massa e pela influência da montagem sobre as medições. Métodos ópticos, como a vibrometria a laser Doppler, oferecem elevada precisão, porém podem apresentar limitações relacionadas à refletividade, ao alinhamento e ao custo. Técnicas baseadas em visão computacional também permitem a análise de vibrações tridimensionais, mas dependem da qualidade das imagens, da visibilidade e de processos de calibração e processamento mais complexos. Nesse contexto, o radar de onda contínua destaca-se como uma alternativa de medição sem contato, apresentando menor dependência das condições visuais do ambiente e possibilitando a detecção de deslocamentos por meio da fase do sinal, além da seleção dos

alvos pela informação de alcance. Essas características tornam essa tecnologia promissora para o monitoramento de vibrações em ambientes industriais. (Su *et al.*, 2026)

2.4 Técnicas Preditivas com Inteligência Artificial

Com os mecanismos de coleta de dados apresentados, é necessário estabelecer métodos capazes de classificar se o dispositivo está operando normalmente ou apresenta falhas potenciais. Diversas abordagens são discutidas na literatura (Alves *et al.*, 2025), sendo algumas delas apresentadas nesta seção.

É importante destacar que nem toda anomalia indica falha: mudanças operacionais, como reparametrizações para novos produtos, também podem alterar os padrões dos sinais. Portanto, os modelos devem ser capazes de diferenciar essas situações.

2.4.1 Transformada de Fourier

A Transformada de Fourier é uma ferramenta fundamental para análise de sinais ao longo do tempo. Trata-se de um algoritmo matemático que converte dados do domínio do tempo para o domínio da frequência, permitindo identificar as frequências predominantes em um sinal.

Segundo Élia Rocha (Rocha, 2025), "uma das principais propriedades da Transformada de Fourier é sua linearidade, permitindo analisar separadamente os componentes de um sinal sem comprometer o resultado final". Essa característica facilita a decomposição e análise dos sinais obtidos por sensoriamento.

2.4.2 Modelos de classificação

Após o pré-processamento dos dados, diversos métodos de classificação podem ser utilizados para o aprendizado supervisionado, no qual o modelo é treinado a partir de dados previamente rotulados para realizar a classificação de novas amostras (Hastie; Tibshirani; Friedman, 2009).

3 METODOLOGIA

Conforme apresentado na seção anterior, existem diversas formas de mensurar e interpretar dados provenientes de um motor elétrico. Este trabalho será desenvolvido com base em um conjunto de dados obtido por meio de um radar de onda contínua, devido à praticidade e à segurança proporcionadas por esse método de medição. Dessa forma, neste capítulo, são apresentados os procedimentos utilizados para a obtenção e o processamento dos dados, bem como as etapas empregadas para a extração das características do sinal, de modo a possibilitar a classificação do estado de funcionamento do equipamento mecânico.

A metodologia está estruturada da seguinte forma: inicialmente, será apresentado o conjunto de dados utilizado, incluindo a forma como os dados foram obtidos e armazenados. Em seguida, serão descritos os métodos empregados para a segmentação dos sinais e a extração das *features* do conjunto de dados. Por fim, serão apresentados os procedimentos de processamento dos dados e os modelos de classificação utilizados para identificar se o equipamento apresenta alguma das falhas consideradas ou se está operando em condições normais.

3.1 Banco de dados utilizado

O banco de dados utilizado como fonte para este trabalho foi obtido na plataforma *Kaggle* e está disponível em (Kaggle, 2026). Os dados disponibilizados são provenientes do experimento apresentado na Figura 6, descrito em (Acar; Acar; Kilic, 2026). A partir dos dados registrados nesse experimento, foram selecionadas e processadas as informações necessárias para a construção do *dataset* utilizado neste trabalho, o qual será posteriormente empregado nas etapas de processamento e classificação.

O experimento é constituído por um motor de indução acoplado a um disco de elevada massa e sustentado por mancais. A montagem experimental foi utilizada para realizar a aquisição dos sinais de radar sob diferentes condições de operação, variando-se parâmetros como velocidade de rotação, carga aplicada e componentes mecânicos utilizados.

A partir dessas variações, foram simuladas diferentes condições de funcionamento do motor, incluindo desbalanceamento, desalinhamento, falhas nas barras do rotor e falhas nos rolamentos. Para cada condição, foram realizadas aquisições dos sinais provenientes do radar, permitindo registrar no banco de dados as diferentes assinaturas associadas ao funcionamento normal e às condições de falha investigadas.

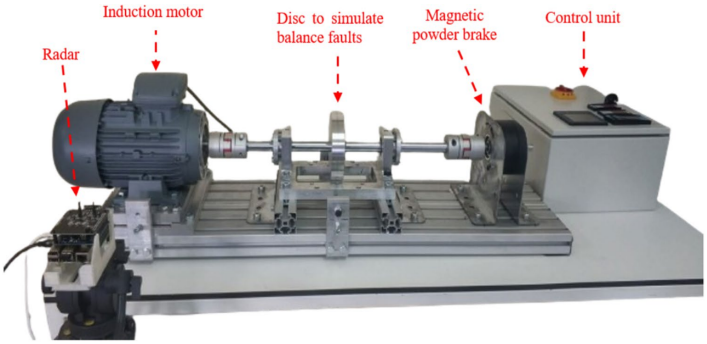


Figura 6 – Montagem do experimento. Retirado de (Acar; Acar; Kilic, 2026).

3.1.1 Obtenção dos dados

Os dados utilizados foram obtidos a partir da demodulação de um sinal proveniente de um radar de onda contínua. Durante a operação do sistema, o radar emite continuamente uma onda eletromagnética que incide sobre o mecanismo apresentado na Figura 6. Devido às vibrações presentes na estrutura do equipamento, o sinal refletido pelo mecanismo apresenta variações de fase em relação ao sinal emitido. Essas variações são utilizadas para caracterizar o comportamento vibracional do equipamento, constituindo a assinatura utilizada como base para o desenvolvimento deste trabalho.

O processo de demodulação fornece duas componentes do sinal: uma componente em fase com o sinal de referência, denominada componente I (*In-phase*), e outra defasada em 90°, denominada componente Q (*Quadrature*). Dessa forma, os dados podem ser representados como um sinal complexo, constituído por uma parte real e uma parte imaginária, conforme apresentado na Equação 3.1:

$$S(t) = I(t) + jQ(t) \tag{3.1}$$

em que $S(t)$ representa o sinal complexo obtido, $I(t)$ corresponde à componente em fase, $Q(t)$ à componente em quadratura e j representa a unidade imaginária.

O instrumento utilizado apresenta uma taxa de amostragem de 10 kHz, sendo cada registro realizado durante um intervalo de 30 s. Dessa forma, cada registro é composto por 300 000 amostras.

3.1.2 Armazenamento dos dados

Os dados obtidos pelo radar foram organizados em uma planilha eletrônica, apresentada na Figura 7, utilizada para a sumarização e identificação dos experimentos realizados. A planilha contém informações referentes à denominação de cada experimento, à velocidade de rotação do motor, à carga aplicada ao disco e à categoria da condição analisada.

	A	B	C	D
2	Data_name	Motor speed (rpm)	Load (Nm)	Class
3	data1	500	0	Normal
4	data2	600	0	Normal
5	data3	700	0	Normal
6	data4	800	0	Normal
7	data5	900	0	Normal
8	data6	1000	0	Normal
9	data7	1100	0	Normal
10	data8	1200	0	Normal
11	data9	1300	0	Normal
12	data10	1400	0	Normal
13	data11	1500	0	Normal
14	data12	500	0,5	Normal
15	data13	600	0,5	Normal
16	data14	700	0,5	Normal

Figura 7 – Sumarização dos experimentos realizados. Imagem elaborado pelo autor.

Para cada experimento, foi disponibilizado um arquivo individual contendo os dados brutos provenientes do radar. Os arquivos foram nomeados de acordo com a denominação atribuída a cada experimento e apresentam uma estrutura semelhante à mostrada na Figura 8. Em cada registro, são armazenados os valores correspondentes às duas componentes do sinal complexo obtido pela demodulação, sendo elas a componente em fase (I(t)) e a componente em quadratura (Q(t)).

	A
1	Q_data,I_data
2	1.3576853069736217,2.403058681247497
3	1.4036528352726982,2.397952639504375
4	1.444512860427432,2.3724224307887614
5	1.3934378289840144,2.260089512440061
6	1.3730078164066466,2.214135136751956
7	1.5211254075925567,2.300937846385043
8	1.47515787929348,2.214135136751956
9	1.3474703006849396,2.127332427118871
10	1.5364479170255798,2.300937846385043

Figura 8 – Exemplo de arquivo contendo os dados brutos de um experimento. Imagem elaborada pelo autor.

Dessa forma, a planilha de sumarização permite relacionar cada conjunto de dados às respectivas condições de operação do equipamento, enquanto os arquivos individuais preservam os sinais obtidos durante os experimentos, que posteriormente serão utilizados nas etapas de processamento e extração de características.

3.1.3 Segmentação dos dados

Quando um motor elétrico apresenta alguma anomalia, alterações em seu comportamento podem ser identificadas a partir de pequenas porções do sinal associado ao seu funcionamento. De maneira análoga, neste trabalho, propõe-se a segmentação dos sinais obtidos pelo radar em janelas de um segundo, de modo a permitir a análise de trechos menores do comportamento do equipamento.

Conforme apresentado anteriormente, cada experimento foi registrado durante 30 s. Dessa forma, cada registro será dividido em 30 segmentos consecutivos, com duração de 1 s cada. Considerando a taxa de amostragem de 10 kHz, cada segmento será constituído por 10 000 amostras das componentes $I(t)$ e $Q(t)$. A imagem 9 demonsta a quantidade de dados antes e depois da aplicação do método de segmentação.

Essa segmentação permite aumentar a quantidade de amostras disponíveis para as etapas posteriores de extração de características e classificação, além de possibilitar que diferentes trechos temporais de um mesmo experimento sejam analisados individualmente. A Figura 9 apresenta a quantidade de amostras do banco de dados antes e após a etapa de segmentação.

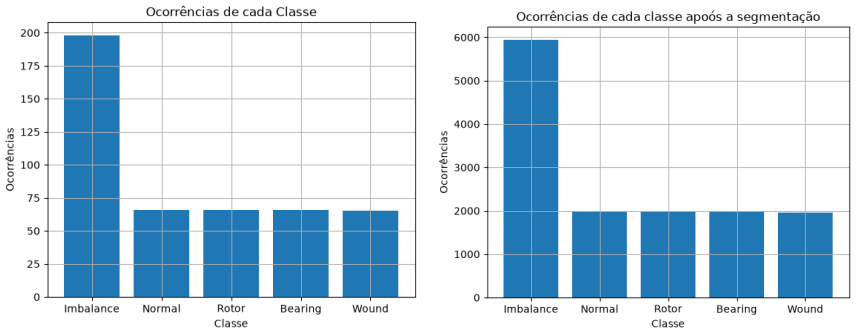


Figura 9 – Quantidade de amostras antes e após o processo de segmentação. Elaborado pelo autor.

3.2 Extração de *Features*

Como é possível observar, cada linha do sumário de experimentos faz referência a um arquivo individual contendo dados brutos da leitura realizada pelo aparelho. Para conseguirmos aplicar em um método de inteligência artificial, será necessário realizar uma extração de features de cada um destes arquivos. Iremos dividir esse tópico em duas etapas, uma extraindo os features diretamente dos dados brutos no domínio do tempo e outra após realizar a transformada de Fourier, extraindo caracteristicas no domínio da frequencia

3.2.1 Domínio do Tempo

Ao realizar a leitura do arquivo, são obtidos os sinais $I(t)$ e $Q(t)$, correspondentes às componentes em fase e em quadratura, respectivamente, do sinal recebido pelo radar. Como primeira etapa de pré-processamento, a partir dessas duas componentes é realizada a transformação para a representação em módulo e fase. Dessa forma, para cada amostra, são obtidos o módulo do sinal e sua respectiva fase, expressa em radianos.

A Figura 10 apresenta o comportamento dos sinais de uma amostra referente a um motor operando em condição normal, antes e após a transformação proposta. As linhas azul e laranja representam, respectivamente, as duas componentes do sinal recebido pelo radar de onda contínua.

Da mesma forma que foi apresentado para uma amostra em condição normal de operação, será apresentado o comportamento das demais classes consideradas neste trabalho, conforme ilustrado na Figura 11. Observa-se que cada classe apresenta caracte-

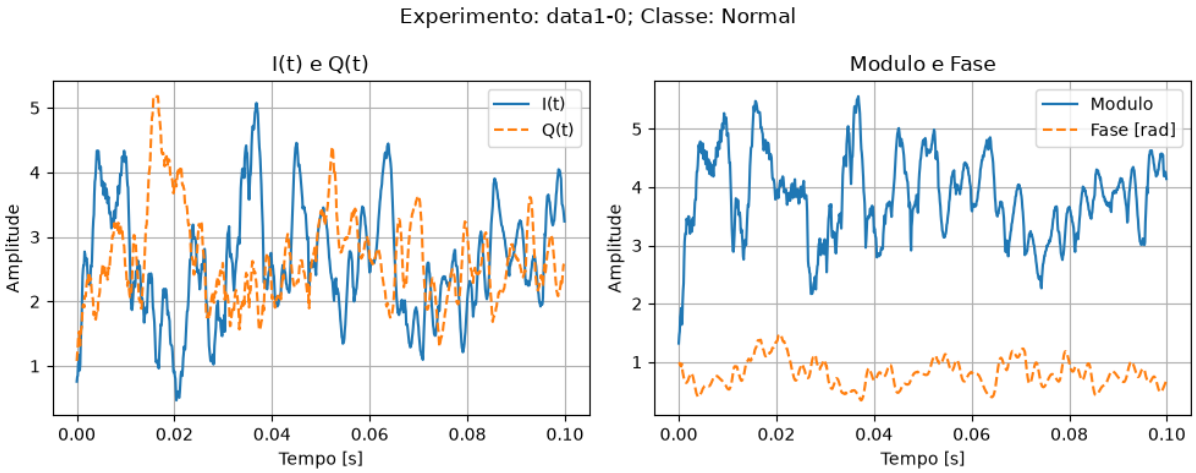


Figura 10 – Exemplo de um motor trabalhando em condição normal. Elaborado pelo autor.

rísticas distintas no comportamento dos sinais, evidenciando diferenças que podem estar relacionadas às respectivas condições de operação do motor.

Como etapa subsequente do processamento, são extraídas características (*features*) no domínio do tempo para cada segmento do sinal. Essas características são utilizadas para compor parte do conjunto de dados que será empregado nas etapas posteriores de análise e classificação. As características selecionadas são apresentadas a seguir:

- **Amplitude:** corresponde à diferença entre o maior e o menor valor do sinal, representando a faixa total de variação dos dados;
- **Energia:** corresponde à soma dos quadrados dos valores do sinal, sendo uma medida da intensidade total do sinal ao longo do intervalo analisado;
- **Curtose:** caracteriza o formato da distribuição dos valores em relação à média, sendo útil para identificar a presença de valores extremos ou eventos impulsivos no sinal;
- **Máximo:** representa o maior valor encontrado no conjunto de dados analisado;
- **Média:** corresponde à soma de todos os valores do sinal dividida pela quantidade de amostras, representando seu valor médio;
- **Mediana:** corresponde ao valor central do conjunto de dados quando as amostras são ordenadas, de modo que metade dos valores se encontra abaixo desse valor e a outra metade acima dele;
- **Mínimo:** representa o menor valor encontrado no conjunto de dados analisado;
- **Moda:** corresponde ao valor que apresenta a maior frequência de ocorrência no conjunto de dados;

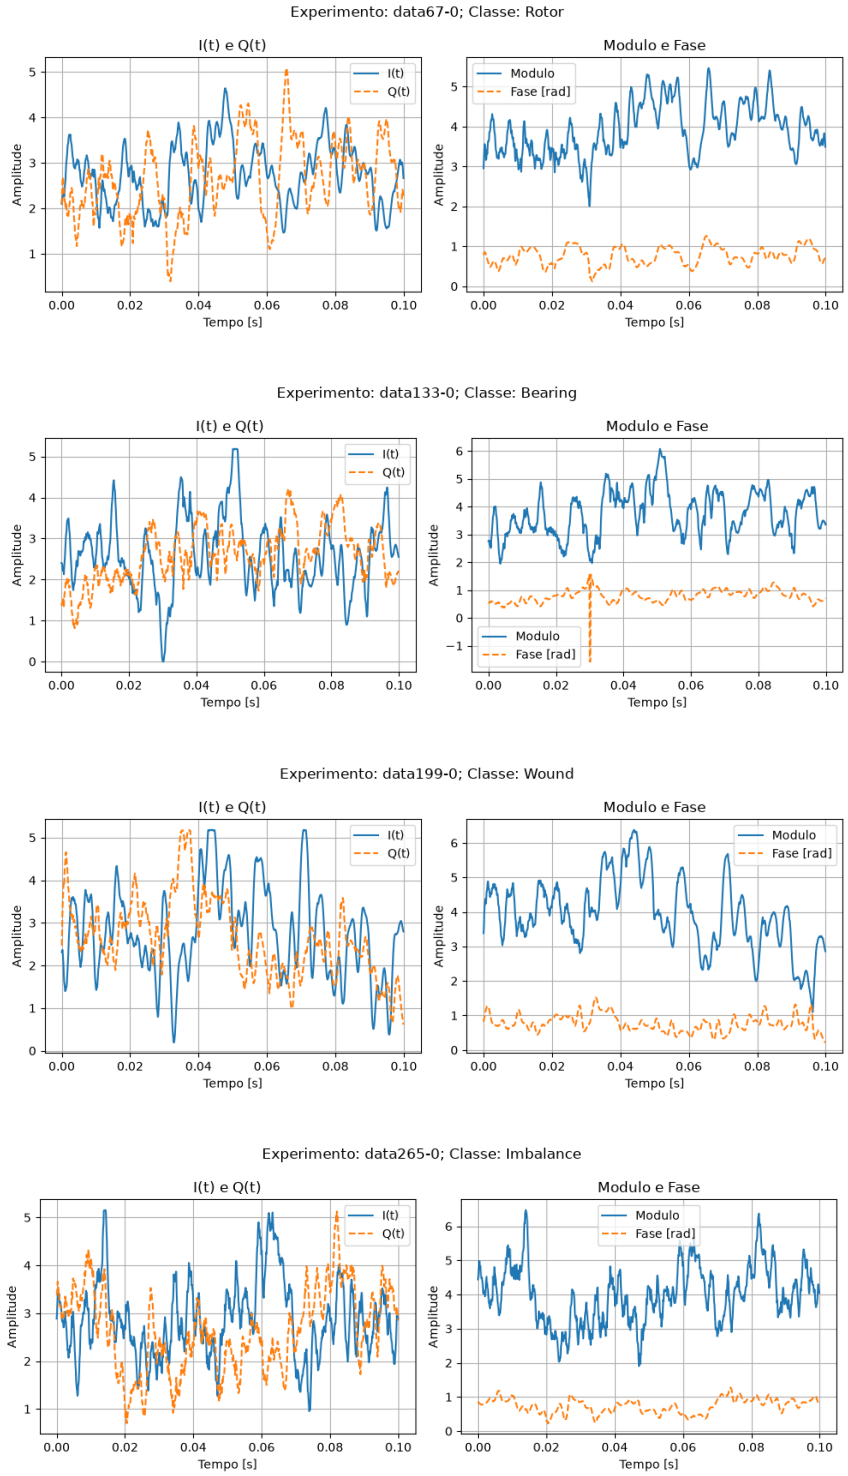


Figura 11 – Demonstração dos dados no domínio do tempo. Elaborado pelo autor.

- **Valor eficaz (RMS):** representa a magnitude efetiva do sinal e é calculado a partir da raiz quadrada da média dos quadrados dos valores das amostras;
- **Assimetria:** caracteriza o grau de assimetria da distribuição dos valores em relação à média. Valores próximos de zero indicam uma distribuição aproximadamente simétrica, enquanto valores positivos ou negativos indicam assimetria em diferentes

direções;

- **Desvio padrão:** mede a dispersão dos valores em relação à média. Valores maiores indicam maior variabilidade do sinal;
- **Variância:** corresponde à média dos quadrados dos desvios dos valores em relação à média, sendo uma medida da dispersão dos dados.

Cada uma das características apresentadas foi extraída individualmente para cada uma das quatro variáveis analisadas: $I(t)$, $Q(t)$, módulo e fase. Dessa forma, considerando as 12 características estatísticas apresentadas, são obtidas 12 *features* para cada variável, totalizando 48 *features* no domínio do tempo para cada segmento do sinal, as quais compõem o banco de dados utilizado nas etapas posteriores deste trabalho.

3.2.2 Domínio da Frequência

Uma forma de analisar sinais oscilatórios que variam ao longo do tempo consiste em investigar as componentes de frequência que contribuem para sua composição. Para isso, é utilizada a Transformada Discreta de Fourier (DFT, do inglês *Discrete Fourier Transform*), que permite representar o sinal no domínio da frequência. Dessa forma, em vez de analisar diretamente a variação da amplitude do sinal ao longo do tempo, obtém-se sua representação espectral, na qual são evidenciadas as diferentes componentes de frequência presentes na amostra.

A análise dessas componentes é particularmente relevante para o estudo do comportamento de equipamentos mecânicos, uma vez que determinadas frequências estão relacionadas às características de operação do sistema, como a velocidade de rotação dos elementos mecânicos. Além disso, alterações no espectro de frequência podem estar associadas à presença de diferentes condições de operação ou falhas no equipamento.

A figura 12 apresenta a representação espectral de uma amostra correspondente a uma condição normal de funcionamento do motor. As linhas verticais destacadas indicam múltiplos da frequência de rotação do motor. Observa-se que diversos picos presentes no espectro estão próximos ou coincidem com essas frequências, evidenciando a relação entre o comportamento espectral do sinal e a dinâmica de rotação do sistema.

Esse comportamento está relacionado à interação entre os diferentes componentes mecânicos do conjunto, cujos movimentos estão associados à rotação do eixo do motor. Dessa forma, componentes periódicos relacionados à rotação podem apresentar contribuições em frequências fundamentais e em seus respectivos múltiplos. Em condições de falha, alterações nesse padrão espectral podem resultar no surgimento ou na intensificação de componentes em frequências características dos elementos afetados, como rolamentos e barras do rotor, conforme apresentado no referencial teórico deste trabalho.

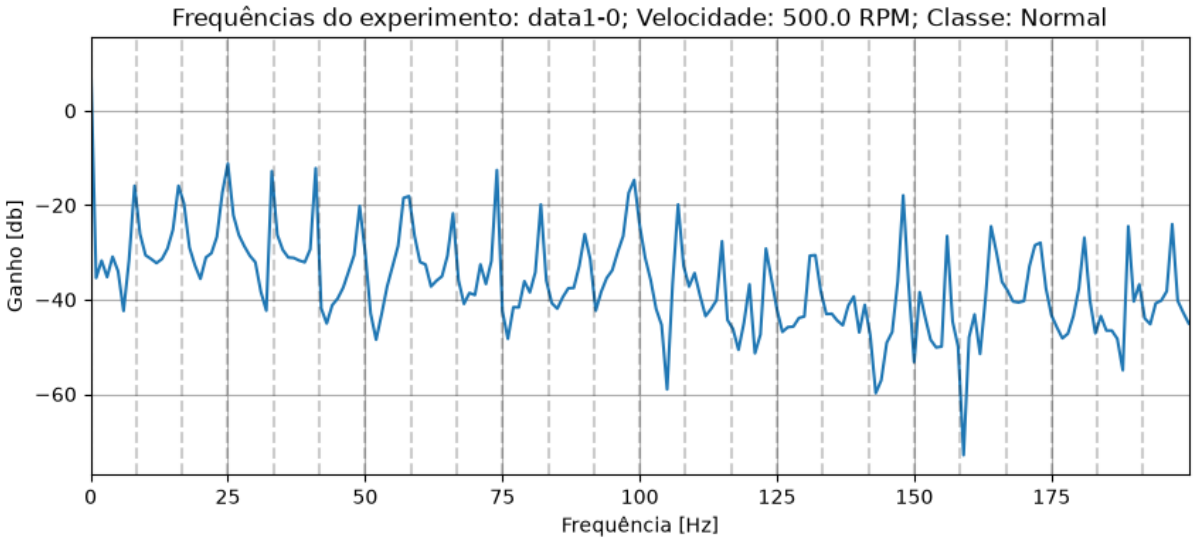


Figura 12 – Representação espectral de um motor operando em condição normal. Elaborado pelo autor.

De forma análoga ao que foi feito no domínio do tempo, será extraído as seguintes características da representação espectral:

- **Largura de banda:** representa a faixa de frequências na qual está concentrada uma parcela significativa da energia do sinal, permitindo caracterizar sua distribuição espectral;
- **Frequência dominante:** corresponde à frequência associada ao maior pico de magnitude no espectro do sinal, indicando o componente de frequência com maior predominância;
- **Magnitude da frequência dominante:** corresponde à magnitude do espectro associada à frequência dominante, indicando a intensidade desse componente de frequência;
- **Energia espectral:** corresponde à energia do sinal distribuída no domínio da frequência, sendo obtida a partir da soma dos quadrados das magnitudes espectrais;
- **Média das frequências:** corresponde à média das frequências presentes no espectro analisado, representando uma medida de tendência central da distribuição espectral;
- **Mediana das frequências:** corresponde ao valor de frequência que divide a distribuição espectral em duas partes, de modo que metade das frequências analisadas encontra-se abaixo desse valor e a outra metade acima;
- **Curtose:** caracteriza o formato da distribuição das componentes espectrais, permitindo identificar concentrações mais acentuadas ou a presença de componentes espectrais extremos;

- **Assimetria:** caracteriza o grau de assimetria da distribuição das componentes espectrais em relação à sua média, indicando a predominância da distribuição para frequências mais baixas ou mais altas.

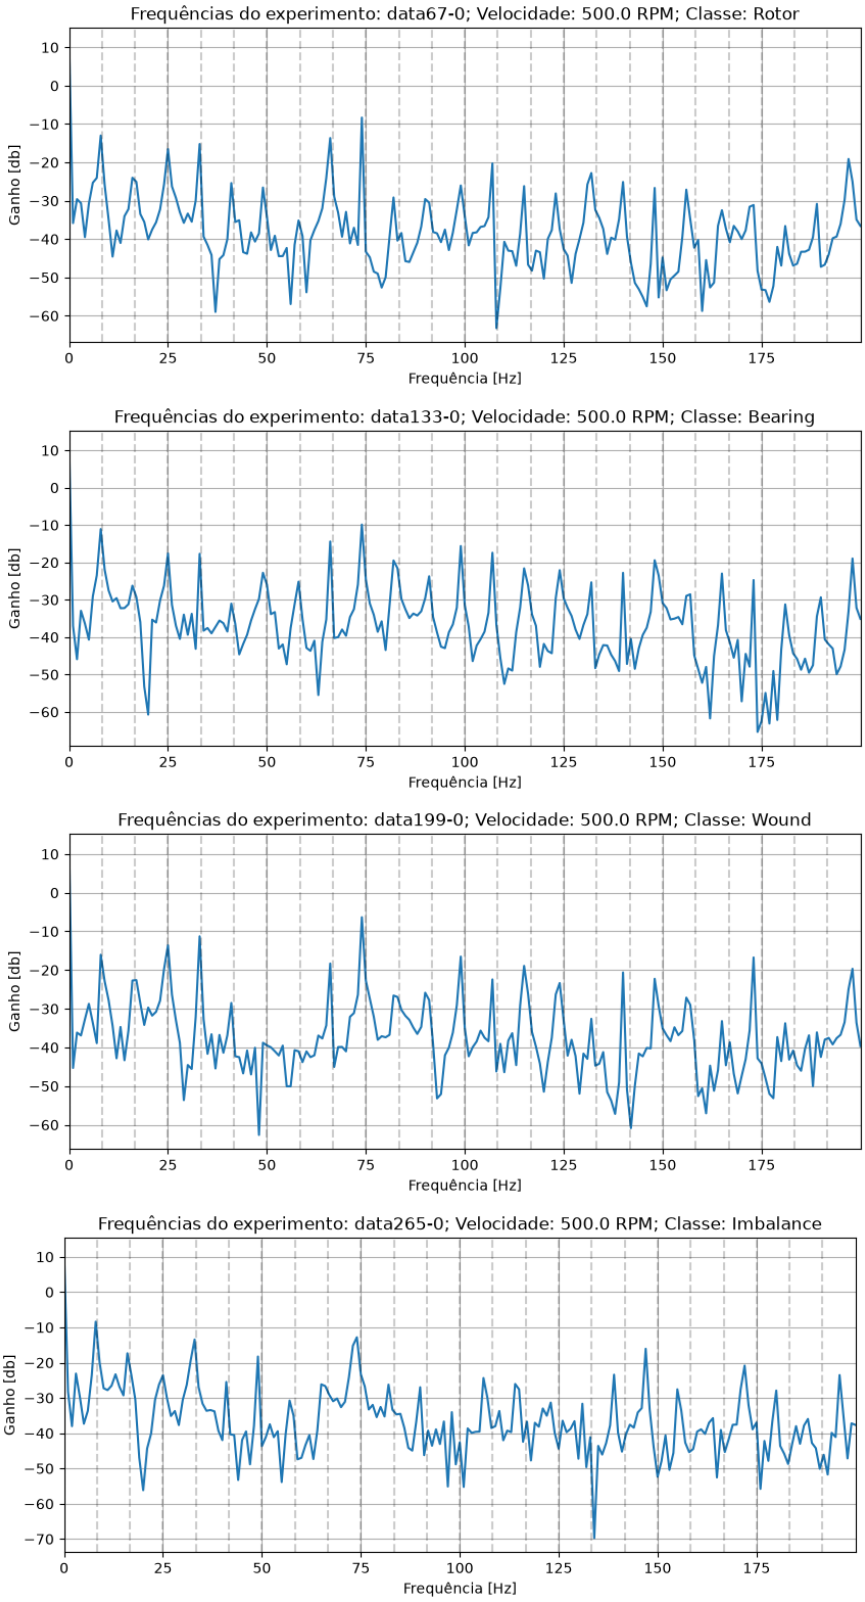


Figura 13 – Demonstração dos dados no domínio da frequência. Elaborado pelo autor.

A partir das etapas descritas anteriormente, obtém-se o banco de dados que será utilizado nas etapas subsequentes deste trabalho. O *dataset* é composto por 48 características (*features*) extraídas no domínio do tempo e 8 características extraídas no domínio da frequência, totalizando 56 *features*. Essas características serão investigadas quanto à sua relevância para a caracterização das diferentes condições de operação do motor e, posteriormente, aquelas consideradas adequadas serão submetidas às etapas de preparação e utilização nos classificadores.

3.3 Preprocessamento dos Dados

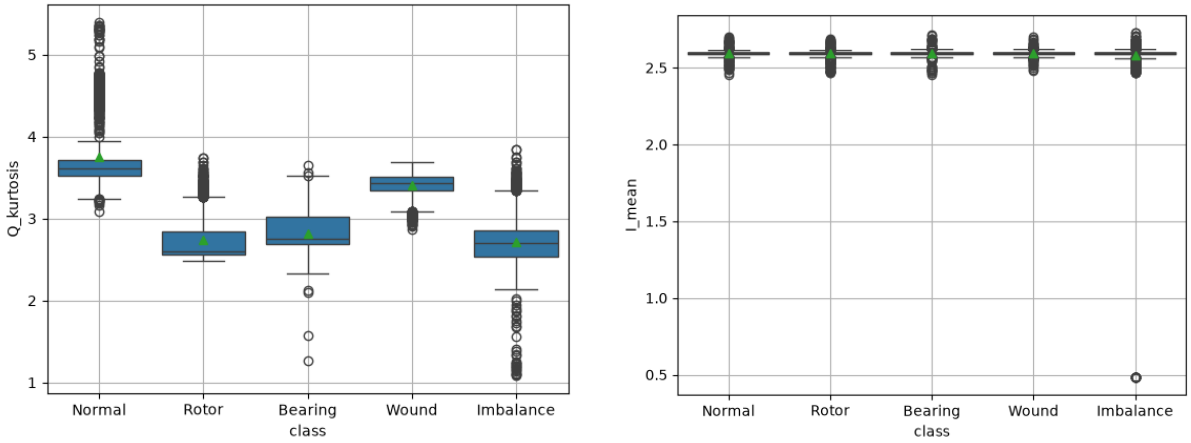
3.3.1 Analise Exploratória

Como observado, o banco de dados apresenta uma quantidade significativa de *features* a serem analisadas. Até o momento, entretanto, não foi realizada uma investigação sobre o comportamento dessas características, suas distribuições, possíveis padrões ou relações entre elas. Dessa forma, esta seção é dedicada à descrição da forma como será realizada a análise exploratória dos dados extraídos, buscando compreender as características do conjunto de dados e identificar possíveis relações entre as *features* e as classes consideradas.

As *features* foram analisadas de forma conjunta, considerando suas respectivas distribuições para cada classe. Para as características extraídas no domínio do tempo, foram utilizados gráficos do tipo *boxplot*, uma vez que esse recurso permite visualizar a distribuição dos dados, sua dispersão e a concentração dos valores em cada classe.

Essa análise teve como objetivo identificar *features* capazes de apresentar diferenças entre as classes, contribuindo para a tarefa de classificação. Como exemplo, a Figura 14a apresenta uma *feature* cuja distribuição permite identificar regiões distintas entre as classes. Nesse caso, observa-se uma menor sobreposição entre os intervalos de valores, indicando que a característica pode apresentar capacidade de discriminação entre as diferentes condições analisadas.

Em contrapartida, na Figura 14b, observa-se uma distribuição semelhante entre as classes, com elevada sobreposição dos valores e comportamentos estatísticos próximos. Dessa forma, essa *feature* apresenta pouca capacidade de diferenciar as classes, uma vez que seus valores assumem regiões semelhantes para diferentes condições. Consequentemente, essa característica será considerada pouco relevante para a classificação e removida das etapas posteriores da análise.



(a) Exemplo que caracteristica que distingue perfeitamente algumas das classes

(b) Exemplo que caracteristica que não distingue perfeitamente as classes

Figura 14 – Comparação entre caracteristicas utilziando boxplot. Elaborado pelo autor.

De forma semelhante, foi realizada a análise das *features* obtidas no domínio da frequência. Neste caso, utilizou-se o gráfico de histograma para representar a distribuição dos valores de cada característica entre as diferentes classes. A análise segue o mesmo princípio apresentado anteriormente: distribuições com elevada sobreposição entre as classes indicam menor capacidade de discriminação, enquanto distribuições distintas sugerem que a *feature* pode contribuir para a diferenciação das condições analisadas. Dessa forma, foram mantidas para a etapa seguinte as características que apresentaram maior capacidade de distinguir as classes.

Por fim, foi realizada uma análise de correlação entre as *features* selecionadas nas etapas anteriores. O objetivo dessa análise foi identificar características que apresentassem forte relação linear entre si. Foi adotado um coeficiente de correlação em módulo superior a 80% como critério para identificar pares de *features* fortemente correlacionadas. Quando duas características apresentaram esse nível de correlação, uma delas foi removida do conjunto de dados, evitando a manutenção de informações redundantes e reduzindo a quantidade de variáveis utilizadas nas etapas posteriores de classificação.

Os resultados dessas análises serão apresentados no capítulo seguinte, juntamente com as *features* removidas do conjunto de dados em cada uma das etapas do processo de seleção.

A partir dessa análise, será avaliada a contribuição de cada característica para a tarefa de classificação. *Features* que apresentarem baixa relevância, comportamento inadequado ou pouca capacidade de diferenciação entre as classes poderão ser removidas do conjunto de dados, de modo a obter um conjunto de características mais adequado às etapas posteriores de classificação.

3.3.2 Balanceamento

Para lidar com o desbalanceamento presente no conjunto de dados, será utilizada a técnica *Synthetic Minority Over-sampling Technique* (SMOTE), proposta por Chawla et al. (Chawla *et al.*, 2002). Diferentemente da simples duplicação de amostras da classe minoritária, o método gera novas amostras sintéticas por meio da interpolação entre uma amostra existente e um de seus k vizinhos mais próximos.

Neste trabalho, o SMOTE será aplicado exclusivamente ao conjunto de treinamento, buscando reduzir a influência do desbalanceamento durante o aprendizado dos modelos. O conjunto de teste será mantido em sua distribuição original, permitindo avaliar os modelos sobre dados não modificados.

3.3.3 Normalização

Alguns métodos de classificação são sensíveis à escala das variáveis, especialmente quando determinadas *features* apresentam amplitudes significativamente maiores que as demais. Portanto, visando estabelecer uma escala comum entre as variáveis, será realizada a normalização *Min-Max*. Essa técnica consiste em transformar os valores de cada *feature* para um intervalo entre 0 e 1, preservando a relação entre os valores originais. A transformação pode ser expressa pela Equação 3.2, em que x representa o valor original da *feature*, $x_{\min}$ e $x_{\max}$ correspondem, respectivamente, aos seus valores mínimo e máximo, e x' representa o valor normalizado.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}, \tag{3.2}$$

3.4 Classificação

Nesse ponto do trabalho, os dados encontram-se preparados para serem utilizados em métodos de classificação. Para a etapa de classificação serão propostos diferentes métodos de aprendizado de máquina, com o objetivo de avaliar o desempenho de diferentes abordagens na classificação das condições de operação do motor.

Inicialmente, os dados serão separados em conjuntos de treinamento e teste. Posteriormente, o conjunto de treinamento será utilizado para ajustar os modelos de aprendizado de máquina, enquanto o conjunto de teste será empregado para avaliar o desempenho dos modelos treinados. Serão utilizados os seguintes algoritmos: Naive Bayes Gaussiano, Árvore de Decisão, *Random Forest*, K-Nearest Neighbors (KNN) e Multilayer Perceptron (MLP).

4 AVALIAÇÃO EXPERIMENTAL

Este capítulo é destinado à apresentação dos principais resultados obtidos a partir da metodologia aplicada. Inicialmente, será apresentada a visualização dos dados do conjunto inicial, bem como as decisões tomadas com base nas análises realizadas. Em seguida, serão apresentadas as métricas utilizadas para avaliação e o desempenho de cada um dos modelos de aprendizado de máquina empregados na classificação dos dados.

4.1 Análise Exploratória das *features*

Conforme apresentado no capítulo de metodologia, o objetivo da análise exploratória é identificar quais *features* apresentam informações relevantes para a classificação. Para isso, busca-se verificar quais características possuem distribuições diferenciáveis entre as classes do conjunto de dados. Foram utilizados dois métodos de visualização para essa análise: no domínio temporal, foram utilizados *boxplots*, enquanto, no domínio espectral, foram utilizados histogramas.

4.1.1 Remoção de *Features* Temporaris

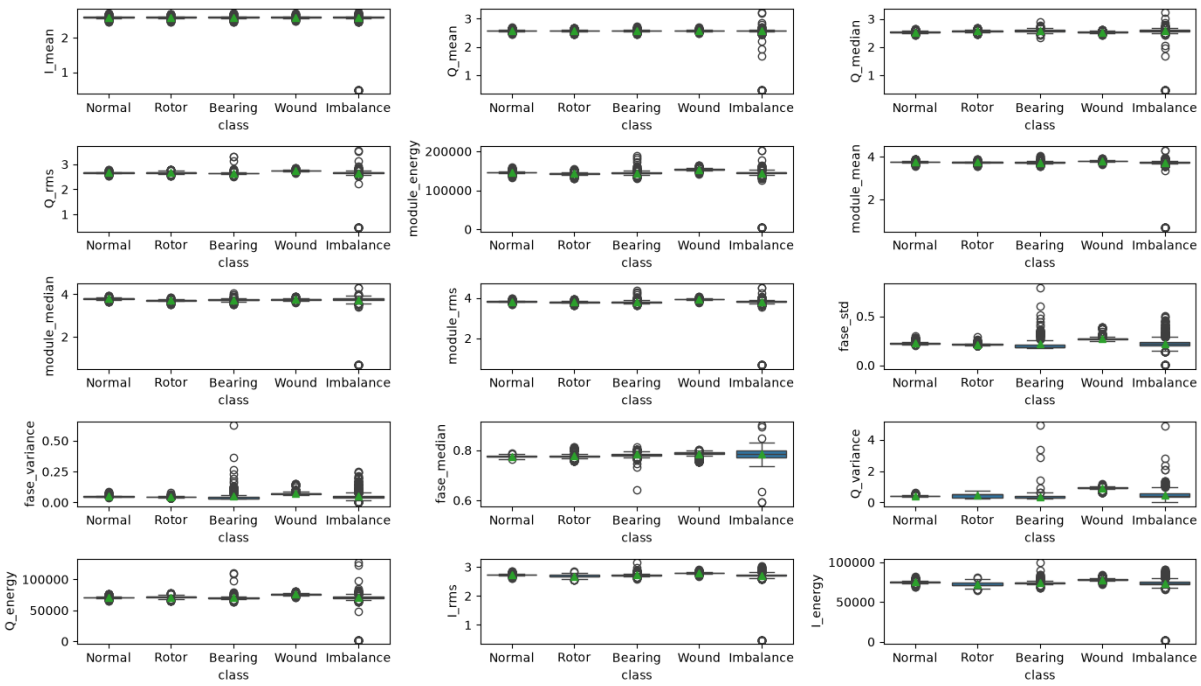


Figura 15 – *Features* no dominio do tempo a serem removidas por não serem capazes de diferenciar as classes. Elaborado pelo autor.

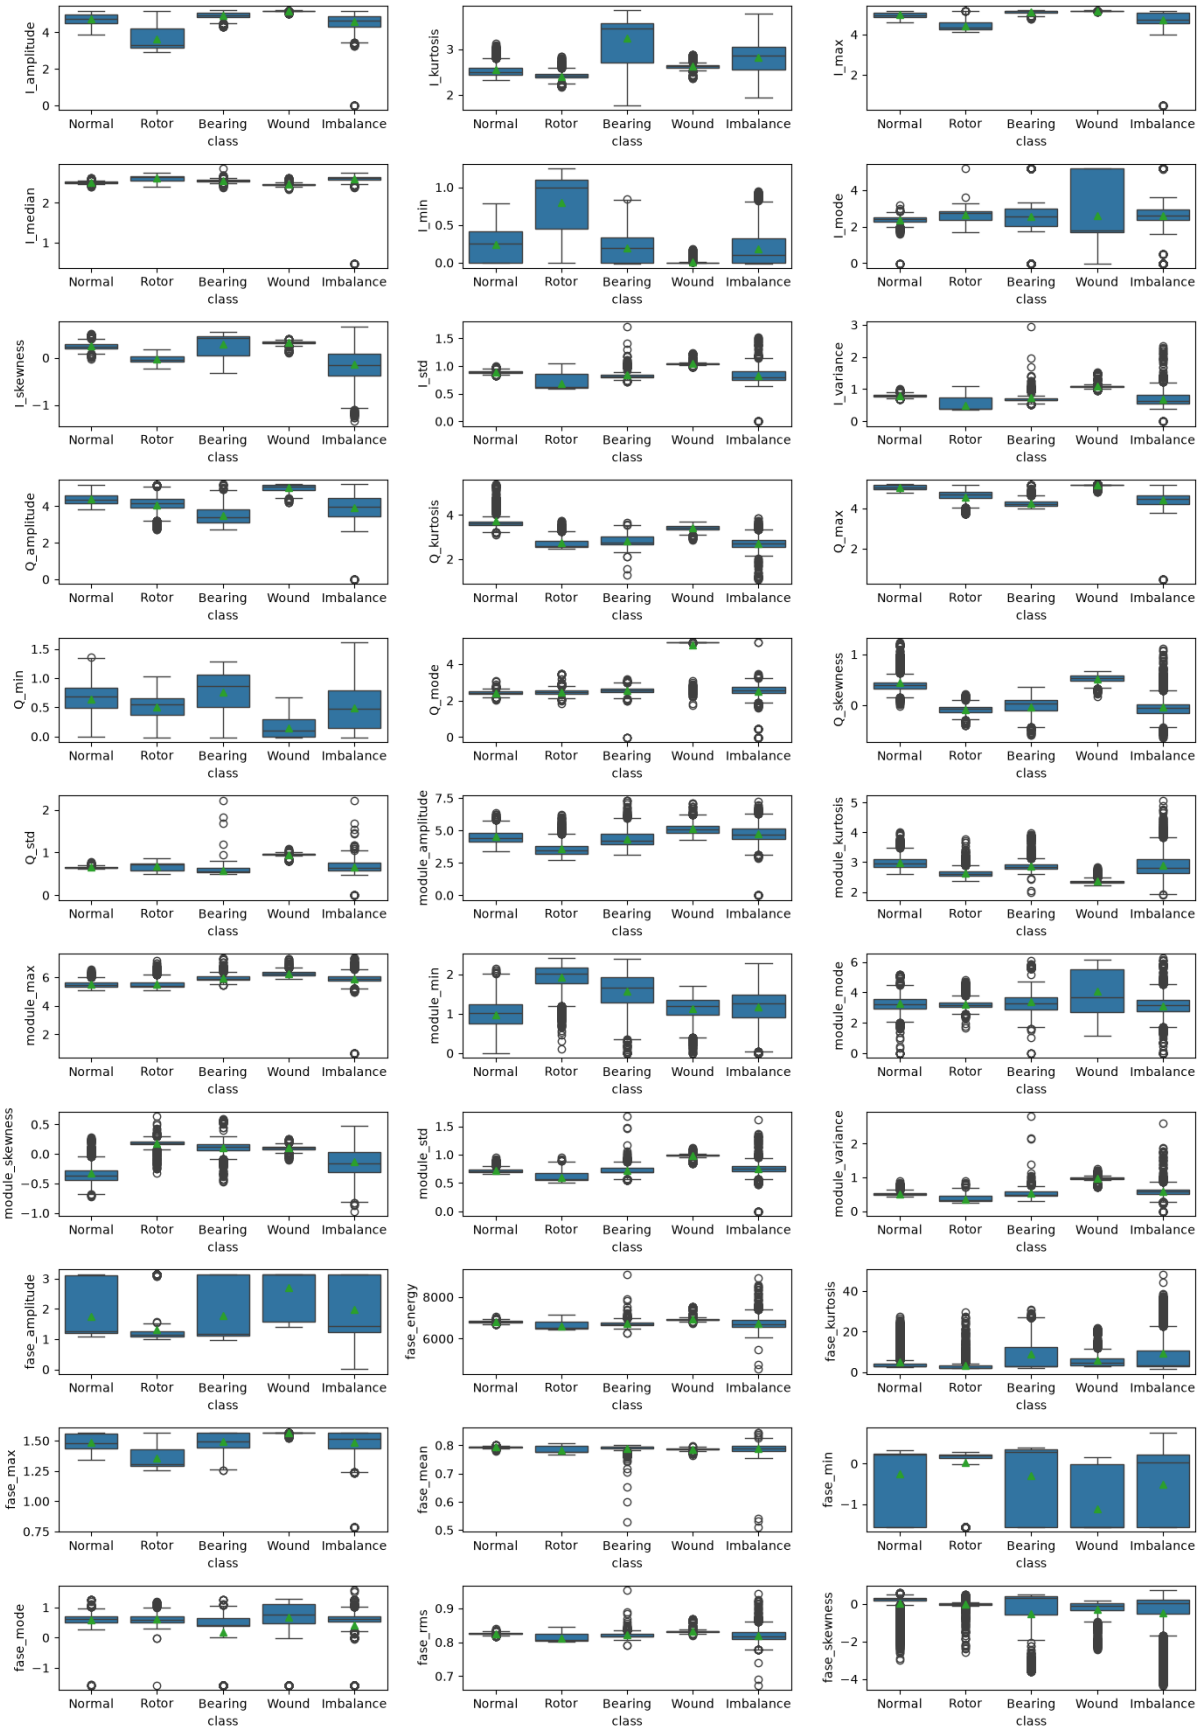


Figura 16 – *Features* no dominio do tempo com informação util para classificação. Elaborado pelo autor.

Neste domínio, foram utilizados *boxplots* para realizar a análise e posterior remoção das *features*. A Figura 15 apresenta gráficos cujas médias e desvios padrões se sobrepõem entre as diferentes classes do problema. Dessa forma, essas informações não contribuem de maneira significativa para a diferenciação das condições analisadas e, portanto, deverão ser removidas do conjunto de dados.

Dessa forma, foram removidas as seguintes *features*: *I_mean*, *Q_mean*, *Q_median*, *Q_rms*, *module_energy*, *module_mean*, *module_median*, *module_rms*, *fase_std*, *fase_variance*, *fase_median*, *Q_variance*, *Q_energy*, *I_rms* e *I_energy*.

A Figura 16 apresenta os *boxplots* das *features* restantes do conjunto de dados. Observa-se que, em todos os gráficos, existem classes cujas distribuições não se sobrepõem, indicando que essas características apresentam potencial para diferenciar as diferentes condições analisadas.

4.1.2 Remoção de *Features* Espectrais

De forma análoga à análise realizada para as *features* no domínio do tempo, foi conduzida uma investigação para as características no domínio da frequência. Entretanto, neste caso, foram utilizados histogramas para avaliar a distribuição dos dados e identificar possíveis sobreposições entre as classes. Conforme apresentado na Figura 17, as *features* selecionadas para remoção apresentam elevada sobreposição entre as classes, indicando que possuem baixa capacidade de diferenciá-las e, consequentemente, tendem a contribuir pouco para o processo de classificação.

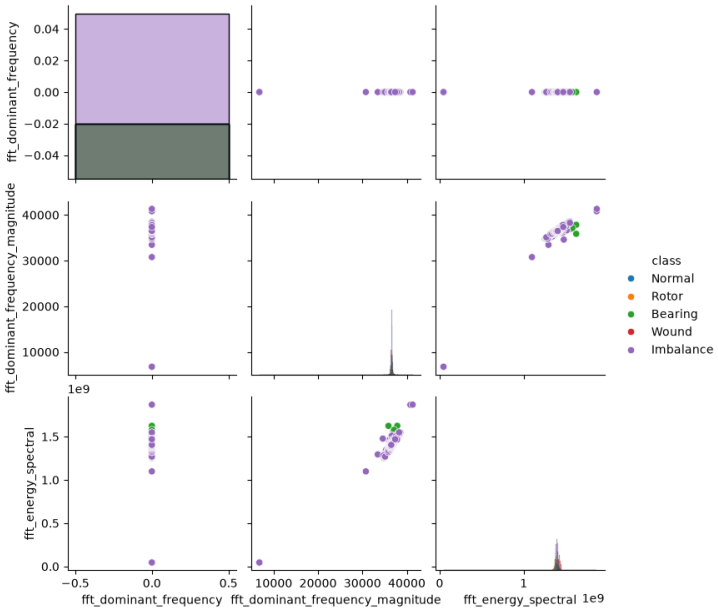


Figura 17 – *Features* no domínio da frequência selecionadas para remoção por apresentarem baixa capacidade de diferenciação entre as classes. Elaborado pelo autor.

Na Figura 18, são apresentados os histogramas e a comparação entre as caracterís-

ticas duas a duas. É possível observar algumas regiões específicas nas quais determinadas classes apresentam maior concentração de amostras. Embora ainda exista uma considerável sobreposição entre as distribuições, essas características apresentam informações capazes de contribuir para a diferenciação das classes e, portanto, foram mantidas no conjunto de dados.

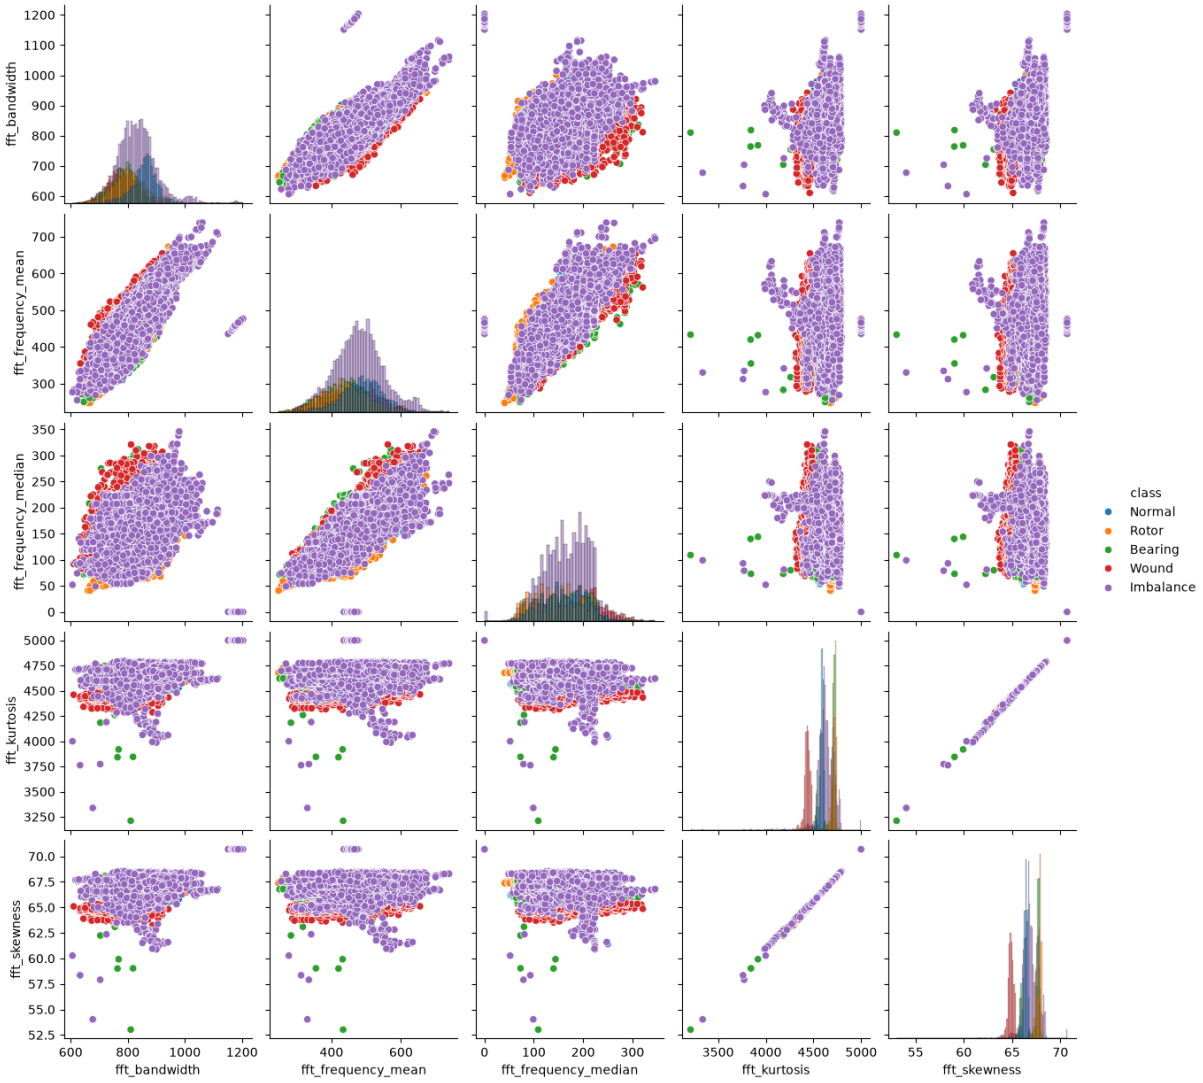


Figura 18 – *Features* no domínio da frequência com informações relevantes para a classificação. Elaborado pelo autor.

Dessa forma, foram removidas as seguintes características: *fft_dominant_frequency*, *fft_dominant_frequency_magnitude* e *fft_energy_spectral*.

4.1.3 Remoção de *Features* de Alta Correlação

Além da análise das distribuições, outro aspecto importante a ser investigado antes da etapa de classificação é a correlação entre as *features*. A análise de correlação permite identificar características que apresentam comportamento semelhante e, consequentemente, podem fornecer informações redundantes ao modelo de classificação.

Como exemplo, na Figura 18, mais especificamente na comparação entre as *features* *fft_kurtosis* e *fft_skewness*, observa-se uma tendência de relação linear entre as variáveis. Nesse caso, conforme os valores de uma característica aumentam, os valores da outra tendem a aumentar também, indicando uma correlação positiva. A presença de características fortemente correlacionadas pode representar redundância no conjunto de dados, uma vez que ambas podem fornecer informações semelhantes para a diferenciação das classes. Dessa forma, quando duas *features* apresentam elevada correlação, uma delas pode ser removida, reduzindo a dimensionalidade do conjunto de dados sem eliminar uma quantidade significativa de informação relevante.

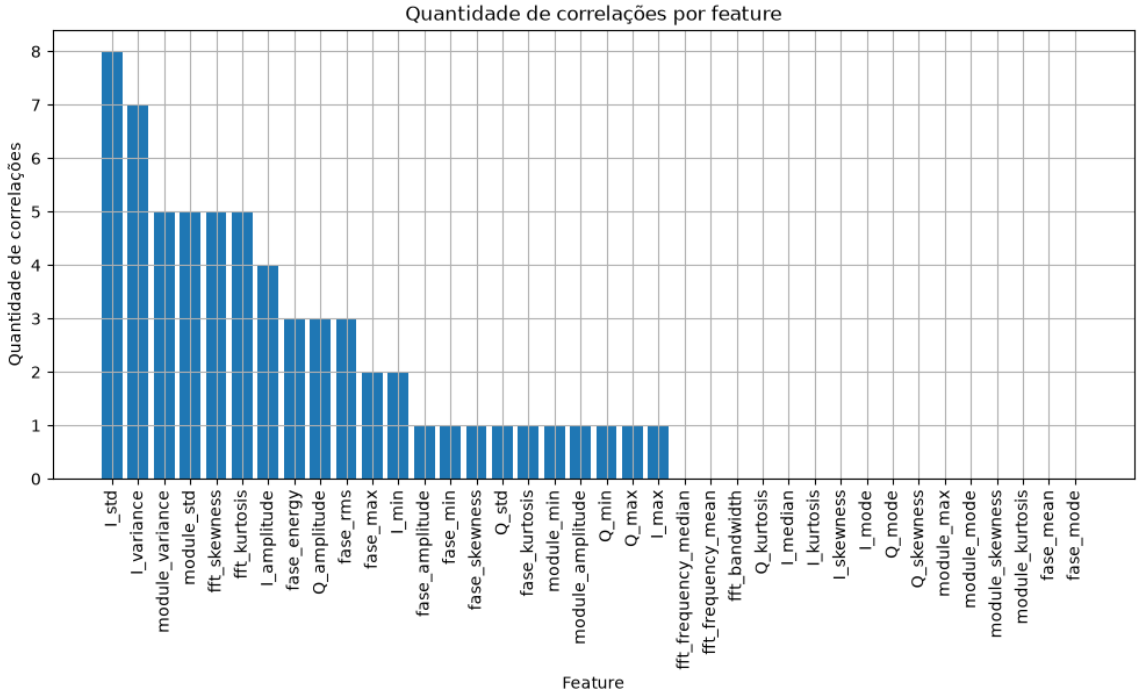


Figura 19 – Quantidade de correlações elevadas identificadas para cada *feature*. Elaborado pelo autor.

A Figura 19 apresenta a quantidade de *features* que possuem forte correlação entre si e que foram consideradas durante o processo de remoção. Para esta análise, foram consideradas fortes as correlações cujo módulo fosse igual ou superior a 0,8. A partir dessas relações, as características foram comparadas e uma delas foi removida quando apresentava informações redundantes em relação à outra.

Após esse processo, a Figura 20 apresenta a matriz de correlação resultante para o conjunto de *features* mantido. Observa-se que as correlações entre as características restantes apresentam módulo inferior a 0.8, indicando a redução das relações lineares fortes no conjunto de dados.

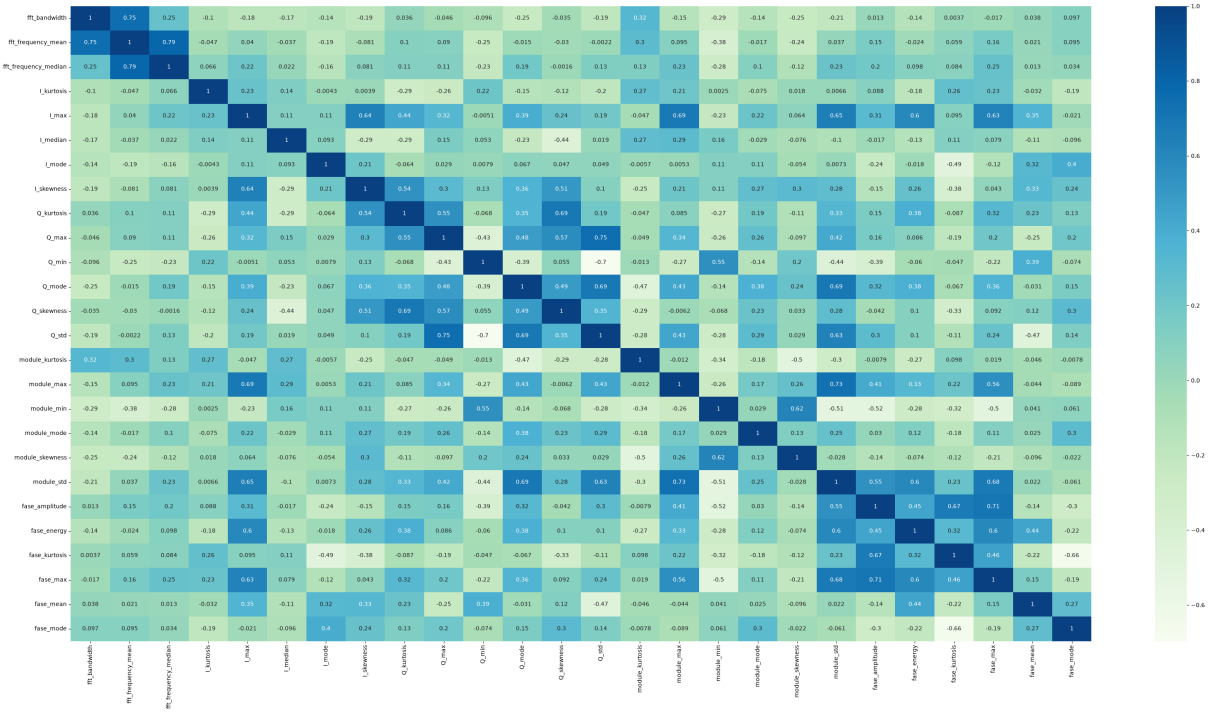


Figura 20 – *Features* restantes após a remoção das características com correlação de módulo igual ou superior a 0,8. Elaborado pelo autor.

Ao final desse processo, foram mantidas 28 características: *motorSpeed*, *load*, *I_kurtosis*, *I_max*, *I_median*, *I_mode*, *I_skewness*, *Q_kurtosis*, *Q_max*, *Q_min*, *Q_mode*, *Q_skewness*, *Q_std*, *module_kurtosis*, *module_max*, *module_min*, *module_mode*, *module_skewness*, *module_std*, *fase_amplitude*, *fase_energy*, *fase_kurtosis*, *fase_max*, *fase_mean*, *fase_mode*, *fft_bandwidth*, *fft_frequency_mean* e *fft_frequency_median*.

4.2 Resultados da Classificação

Após a etapa de seleção das *features* e normalização dos dados, o conjunto de características resultante será utilizado como entrada para diferentes métodos de *machine learning* destinados à classificação das falhas presentes no motor. Os modelos serão avaliados a partir de diferentes métricas de desempenho, permitindo analisar o comportamento de cada método diante do problema proposto.

Os métodos de classificação utilizados são:

1. **Naive Bayes Gaussiano**: método de classificação baseado em princípios estatísticos e no teorema de Bayes, assumindo uma distribuição gaussiana para as características;
2. **Árvore de Decisão**: modelo que realiza a classificação por meio da divisão sucessiva dos dados com base nos valores das *features*;
3. ***Random Forest***: modelo baseado na combinação de múltiplas árvores de decisão, cuja classificação é determinada a partir do conjunto de previsões das árvores;

4. ***K-Nearest Neighbors* (KNN)**: método que realiza a classificação de uma amostra com base nas classes dos seus K vizinhos mais próximos;

5. ***Multilayer Perceptron* (MLP)**: modelo baseado em redes neurais artificiais, composto por camadas de neurônios interconectados capazes de aprender relações entre as características de entrada e as classes.

Nesta seção, serão apresentados os resultados obtidos pelos diferentes métodos de classificação, considerando diferentes configurações de seus respectivos hiperparâmetros. Além do desempenho obtido nos dados de treinamento e teste, será analisada a diferença entre esses resultados com o objetivo de identificar possíveis sinais de *overfitting*. Dessa forma, serão selecionadas configurações que apresentem bom desempenho de classificação e, simultaneamente, capacidade de generalização para dados não utilizados durante o treinamento.

4.2.1 Classificador - Naive Bayes Gaussiano

Nesta parte, foram avaliadas duas configurações do classificador Naive Bayes Gaussiano. Na primeira, o modelo foi treinado utilizando o conjunto de treinamento e, posteriormente, avaliado sobre um conjunto de teste não utilizado durante o processo de treinamento. Na segunda configuração, o modelo foi treinado utilizando todo o conjunto de dados disponível e, em seguida, avaliado sobre esse mesmo conjunto.



(a) Matriz de confusão do modelo de Naive Bayes Gaussiano aplicado ao conjunto de teste.

(b) Matriz de confusão do modelo de Naive Bayes Gaussiano aplicado ao conjunto completo.

Figura 21 – Matrizes de confusão obtidas para o classificador Naive Bayes Gaussiano nas diferentes configurações avaliadas. Elaborado pelo autor.

O primeiro modelo apresentou uma acurácia de 90% tanto no conjunto de treinamento quanto no conjunto de teste. A proximidade entre os resultados indica que o modelo apresentou comportamento consistente entre os dados utilizados durante o treinamento e aqueles não observados anteriormente. Dessa forma, não foi observada uma diferença significativa de desempenho que indique a ocorrência de sobreajuste (*overfitting*). Conforme apresentado na Figura 21a, a classe na qual o modelo apresentou maior dificuldade de classificação foi a de desbalanceamento.

O segundo modelo também apresentou uma acurácia de 90%. Entretanto, como o modelo foi avaliado utilizando as mesmas amostras empregadas durante o treinamento, esse resultado representa seu desempenho sobre os dados conhecidos. Portanto, essa configuração não permite avaliar adequadamente a capacidade de generalização do modelo ou identificar a ocorrência de sobreajuste. A matriz de confusão correspondente é apresentada na Figura 21b.

4.2.2 Classificador - Árvore de Decisão

Existem dois dos principais critérios de impureza utilizados para determinar como os dados serão divididos em uma Árvore de Decisão: o índice Gini e a Entropia. Dessa forma, foram avaliados diferentes modelos, variando a profundidade máxima da árvore para cada um desses critérios e registrando-se a acurácia obtida em cada configuração. Os resultados podem ser observados na Figura 22.

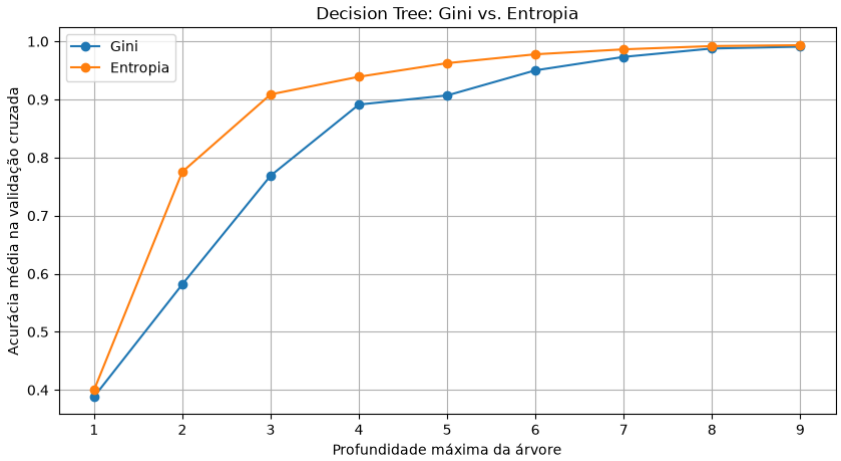
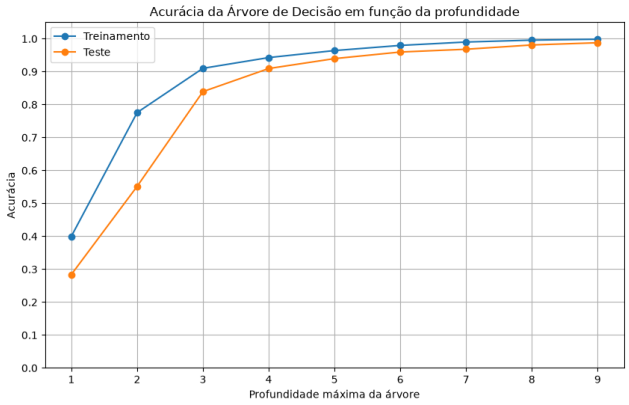


Figura 22 – Comparação entre a profundidade máxima e o critério de divisão utilizado na Árvore de Decisão.

Observa-se que a Entropia apresentou melhores resultados para árvores com menor profundidade, obtendo, por exemplo, valores superiores a 90% de acurácia no conjunto de validação com uma profundidade máxima de 3 níveis. De maneira geral, à medida que a profundidade da árvore aumenta, os resultados obtidos pelos dois critérios tendem a se aproximar de 100% de acurácia no conjunto de treinamento. Entretanto, árvores com elevada profundidade apresentam maior complexidade e podem se ajustar excessivamente às características específicas dos dados utilizados no treinamento, indicando uma possível ocorrência de sobreajuste, visto que não há ganho significativo de desempenho que justifique o aumento da complexidade do modelo.

A partir desse resultado, foi realizada uma análise mais detalhada da acurácia obtida pelo critério de Entropia em função da profundidade da árvore, comparando-se o desempenho nos conjuntos de validação e teste, conforme apresentado na Figura 23a.

Observa-se que, a partir de uma profundidade máxima de aproximadamente 4 níveis, a acurácia apresenta pouca variação em ambos os conjuntos. Nesse intervalo, o modelo apresenta uma acurácia de aproximadamente 91,96% no conjunto de teste, enquanto a acurácia no conjunto de treinamento gira em torno de 94,29%, conforme a figura 23b.



(a) Acurácia em função da profundidade máxima.

Profundidade	Treino	Teste
1	40,00%	28,39%
2	77,59%	55,17%
3	91,02%	83,95%
4	94,29%	90,96%
5	96,42%	93,97%
6	97,98%	95,97%
7	99,01%	96,82%
8	99,59%	98,12%
9	99,87%	98,79%

(b) Acurácias de teste e validação com diferentes profundidades.

Figura 23 – Comparativo de desempenho entre diversos modelos de arvore de decisão, variando sua profundidade.

Além da análise da acurácia, outra informação relevante obtida a partir da Árvore de Decisão é a identificação das características mais utilizadas pelo modelo durante o processo de classificação. A Figura 24 apresenta a estrutura da árvore e as características selecionadas em seus diferentes ramos. Observa-se que a característica *Q_skewness* foi utilizada na raiz da árvore, indicando que ela foi considerada na primeira divisão dos dados. Em seguida, destacam-se as características *I_kurtosis* e *Q_std*, utilizadas no nível posterior da árvore.

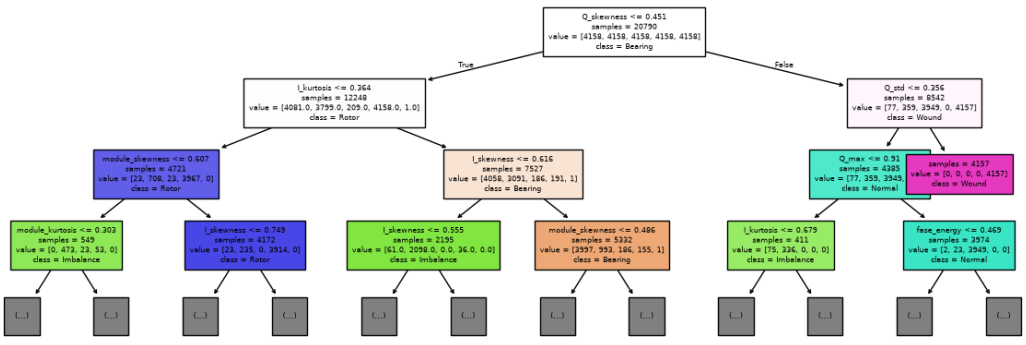


Figura 24 – Características utilizadas nos diferentes níveis da Árvore de Decisão.

4.2.3 Classificador - *Random Forest*

O *Random Forest* é um método de classificação baseado na combinação de diversas Árvores de Decisão. Cada árvore realiza uma classificação individual e, posteriormente, as previsões são combinadas para determinar a classe da amostra. Dessa forma, uma das

análises realizadas nesta seção consiste em avaliar a acurácia do modelo em função da quantidade de estimadores e da profundidade máxima das árvores, conforme apresentado na Figura 25.

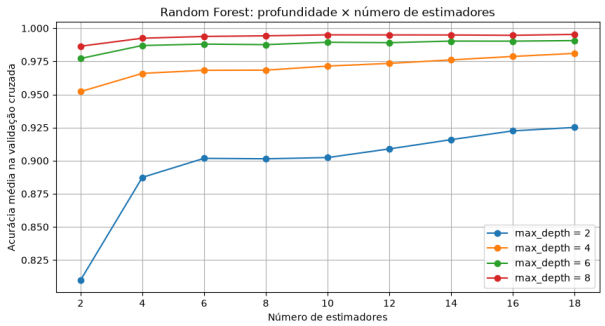


Figura 25 – Comparação entre a quantidade de árvores e a profundidade máxima no modelo *Random Forest*.

A partir dos resultados apresentados, observa-se que uma *Random Forest* composta por 2 árvores com profundidade máxima de 4 níveis apresentou desempenho superior ao modelo composto por 18 árvores com profundidade máxima de 2 níveis. Esse resultado demonstra que o aumento da quantidade de estimadores, isoladamente, não garante um melhor desempenho, sendo necessário considerar também a profundidade das árvores que compõem o modelo. Dessa forma, a escolha dos hiperparâmetros deve buscar um equilíbrio entre a complexidade do modelo e sua capacidade de classificação.

Observa-se também que, para o conjunto de dados analisado, o aumento da quantidade de estimadores para valores superiores a 4 não produz alterações expressivas na acurácia. De maneira semelhante, para profundidades superiores a 4 níveis, não são observadas melhorias significativas no desempenho do modelo. Dessa forma, a configuração composta por 4 estimadores e profundidade máxima de 4 níveis foi selecionada para uma análise mais detalhada da relação entre a profundidade e as acurácias obtidas nos conjuntos de treinamento e teste. Esse resultado é apresentado na Figura 26.

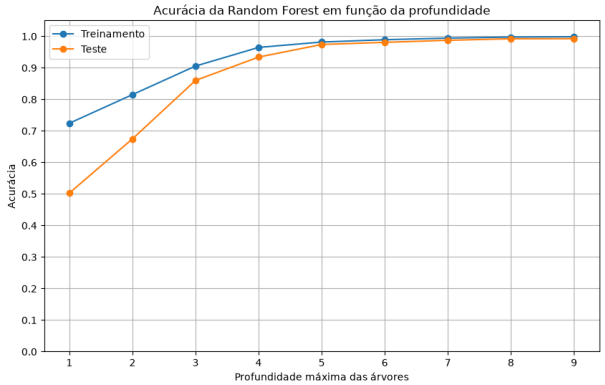


Figura 26 – Acurácia de uma *Random Forest* com 4 estimadores em função da profundidade máxima das árvores.

Para a configuração selecionada, composta por 4 estimadores e profundidade máxima de 4 níveis, foi obtida uma acurácia de 96,49% no conjunto de treinamento e 93,42% no conjunto de teste. A pequena diferença entre os resultados indica que o desempenho do modelo se manteve próximo ao avaliar dados não utilizados durante o treinamento. Além disso, a elevada acurácia obtida no conjunto de teste demonstra que essa configuração apresentou bom desempenho na classificação das diferentes classes presentes no conjunto de dados.

4.2.4 Classificador - *K-Nearest Neighbors*

No classificador *K-Nearest Neighbors* (KNN), foi analisada a influência do número de vizinhos considerados, representado pelo parâmetro K, sobre a acurácia do modelo. Os resultados indicaram uma redução da acurácia à medida que o valor de K foi aumentado, conforme apresentado na Figura 27.

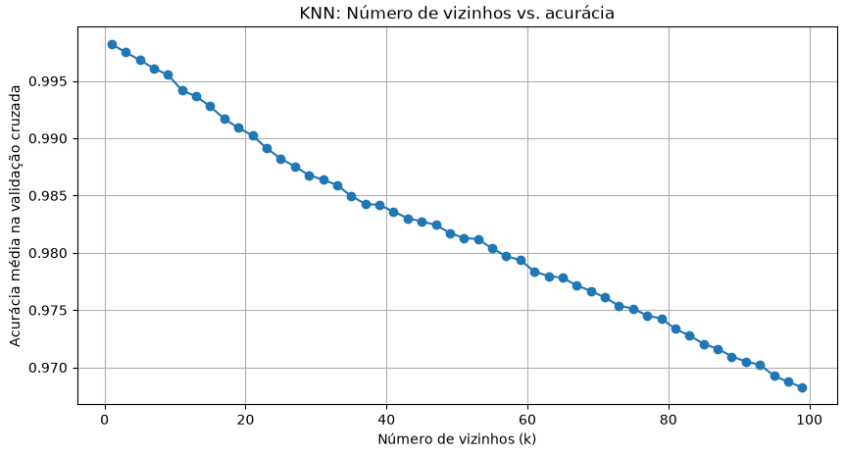


Figura 27 – Acurácia do modelo KNN em função do número de vizinhos considerados.

Esse comportamento pode ser explicado pelo fato de que valores maiores de K fazem com que uma quantidade maior de amostras seja considerada durante a classificação de cada elemento. Dessa forma, amostras pertencentes a diferentes classes podem ser incluídas na mesma vizinhança, dificultando a diferenciação entre elas. Em contrapartida, valores menores de K permitem que a classificação seja determinada por uma região mais próxima da amostra analisada, preservando melhor as características locais de separação entre as classes.

Assim, para o conjunto de dados analisado, os menores valores de K apresentaram melhor desempenho de classificação. Para auxiliar na interpretação desse comportamento, a Figura 28 apresenta as regiões de decisão obtidas pelo KNN para diferentes valores de K, considerando as características *Q_skewness* e *I_kurtosis*.

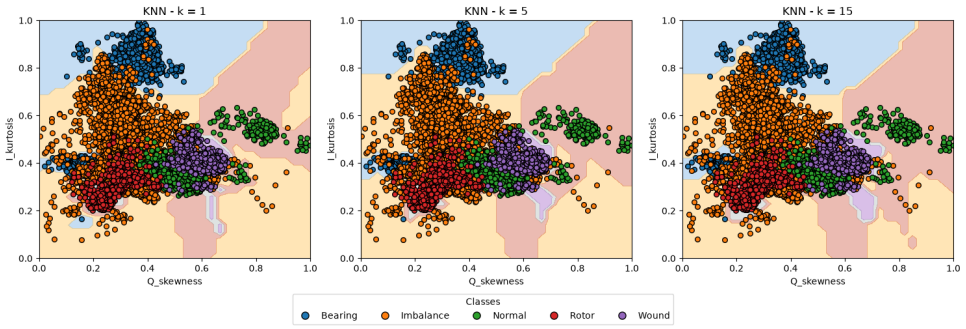


Figura 28 – Regiões de decisão obtidas pelo modelo KNN para diferentes valores de K.

Para $K = 1$, observa-se que as regiões de decisão apresentam maior variação e acompanham mais de perto a distribuição local das amostras. Isso ocorre porque a classificação de cada elemento é determinada exclusivamente pelo seu vizinho mais próximo. À medida que o valor de K aumenta, uma quantidade maior de amostras passa a ser considerada durante a classificação, fazendo com que as fronteiras entre as classes se tornem mais suaves e abrangentes.

Também é possível observar que algumas classes apresentam regiões de concentração relativamente bem definidas. A classe *Bearing*, por exemplo, apresenta uma concentração predominante na região superior do gráfico, enquanto as classes *Normal*, *Rotor* e *Wound* apresentam agrupamentos mais concentrados em regiões específicas do espaço de características. Por outro lado, a classe *Imbalance* apresenta maior dispersão e sobreposição com as demais classes, principalmente nas regiões de fronteira.

Esse comportamento indica que, embora exista sobreposição entre as classes, as amostras apresentam uma tendência de agrupamento em determinadas regiões do espaço de características. Dessa forma, valores menores de K permitem que o classificador explore com maior precisão essas características locais. Com o aumento de K, a influência de amostras pertencentes a outras classes torna-se maior, modificando as fronteiras de decisão e reduzindo a capacidade do modelo de representar as separações locais existentes nos dados. Dessa forma, conforme aumentamos o valor de k, observa-se uma redução da acurácia, indicando que o modelo apresenta uma menor capacidade de distinguir as diferentes classes. Para $k = 1$, o modelo obteve 100% de acurácia no conjunto de treinamento e 99% no conjunto de teste, conforme apresentado na Figura 29.

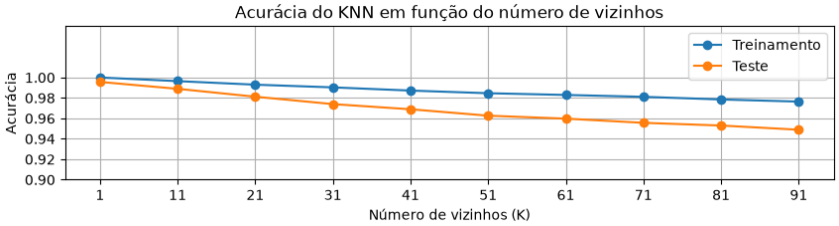


Figura 29 – Comparativo de acurácia entre treinamento e teste para o KNN em função do k

4.2.5 Classificador - Multilayer Perceptron

O último modelo de classificação utilizado é o *Multilayer Perceptron* (MLP), composto por uma camada intermediária. Nesse modelo, foi variada a quantidade de neurônios dessa camada, com o objetivo de avaliar seu impacto no desempenho do classificador. A Figura 30 apresenta o desempenho dos modelos para diferentes quantidades de neurônios.

Observa-se que o modelo com apenas 2 neurônios não foi capaz de distinguir adequadamente as classes, apresentando uma acurácia de aproximadamente 60%. À medida que a quantidade de neurônios da camada intermediária é aumentada, o modelo apresenta valores cada vez maiores de acurácia, atingindo esses resultados com uma quantidade menor de épocas. Entretanto, o aumento excessivo da quantidade de neurônios pode aumentar a complexidade do modelo sem necessariamente trazer um ganho muito expressivo de desempenho.

Em todos os casos analisados, a acurácia obtida no conjunto de treinamento apresentou valores próximos aos observados no conjunto de teste, indicando que não houve uma diferença significativa entre o desempenho do modelo nesses dois conjuntos.

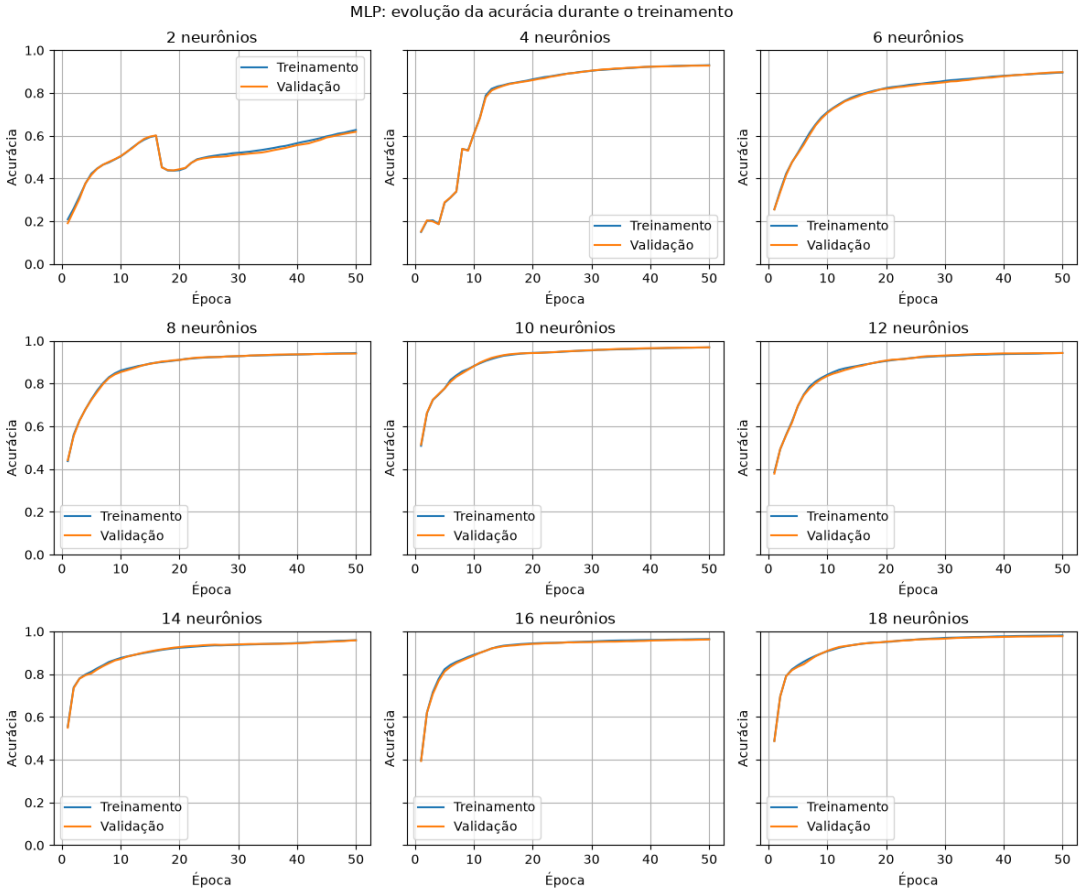


Figura 30 – Acurácia de treino e teste em função da quantidade de neurônios da camada intermediária

5 CONCLUSÕES

De forma geral, os modelos de classificação avaliados apresentaram resultados satisfatórios na identificação das diferentes condições de funcionamento do motor a partir dos dados obtidos pelo radar de onda contínua.

O classificador *Naive Bayes* Gaussiano apresentou uma acurácia de aproximadamente 90%, demonstrando um bom desempenho na classificação das condições analisadas. Entretanto, conforme observado na matriz de confusão, o modelo apresentou maior dificuldade na identificação da classe *Imbalance* (Desbalanceamento).

O modelo baseado em árvore de decisão apresentou acurácia de aproximadamente 91% para valores intermediários de profundidade máxima. Durante a análise das *features*, destacaram-se *Q_skewness*, *I_kurtosis* e *Q_std*, que apresentaram relevância na distinção entre as classes. Essas características também se mostraram importantes para a classificação por outros métodos de *machine learning*, como o KNN.

O modelo de *Random Forest* mostrou que, a partir de determinado número de estimadores, o aumento dessa quantidade não proporcionou mudanças significativas na acurácia. Por outro lado, a profundidade das árvores apresentou maior influência sobre o desempenho do modelo.

O KNN foi o modelo que apresentou a maior acurácia entre os classificadores avaliados. Esse resultado pode estar relacionado à forma como os dados foram segmentados. A segmentação dos sinais em janelas de um segundo introduziu diferentes variações dentro de uma mesma classe, contribuindo para a formação de regiões de maior concentração dos dados no espaço de características. Apesar disso, ainda foi observada sobreposição entre algumas classes, conforme apresentado nas análises realizadas.

O *Multilayer Perceptron* não apresentou desempenho satisfatório quando configurado com uma quantidade reduzida de neurônios na camada intermediária. Entretanto, para configurações com mais de quatro neurônios, o modelo apresentou acurácia superior a 90%, demonstrando que o aumento da capacidade da camada intermediária contribuiu para a melhoria do desempenho da classificação.

Por fim, os resultados obtidos neste trabalho demonstram a viabilidade da utilização de um radar de onda contínua para a identificação e classificação de diferentes condições de funcionamento de motores elétricos. Mesmo utilizando amostras curtas, foi possível extrair características dos sinais e obter resultados de classificação superiores a 90% em diferentes modelos de *machine learning*. Dessa forma, o método apresenta potencial para aplicações de monitoramento e diagnóstico de falhas em motores, especialmente em situações nas quais se busca realizar a análise dos sinais em intervalos reduzidos.

REFERÊNCIAS BIBLIOGRÁFICAS

ACAR, Y. E.; ACAR, Z. Y.; KILIC, M. E. Radar-based electrical machine fault diagnosis via time–frequency imaging and deep feature-based machine learning. **Electrical Engineering**, v. 108, p. 315, 2026.

ALLELCO. **Sensores acelerômetros: definição, tipos, aplicações, funções e comparação de giroscópio**. 2025. Disponível em: https://www.allelcoelec.pt/blog/Accelerometer-Sensors-Definition,Types,Applications,Functions,and-Gyroscope-Comparison.html. Acesso em: 12 set. 2026.

ALVES, L. d. S. *et al.* **Uso de inteligência artificial para desenvolvimento de algoritmo de previsão de falhas para motores de indução trifásicos: uma revisão sistemática de literatura**. [*S.l.: s.n.*], 2025. Edição 55 | 2025. Disponível em: https://revistas.unifoa.edu.br/cadernos/article/view/5536. Acesso em: 12 abr. 2026.

CASTRO, R. **Guia completo: conheça os diversos tipos de motores**. [*S.l.: s.n.*], 2024. Disponível em: https://www.casadomotoreletrico.com.br/blog/categorias/rebobinamento/guia-completo-conheca-os-diversos-tipos-de-motores. Acesso em: 13 abr. 2026.

CHAWLA, N. V. *et al.* Smote: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

CORDEIRO, E. **Motores elétricos: componentes e suas aplicações**. [*S.l.: s.n.*], 2022. Disponível em: https://revistamanutencao.com.br/literatura/tecnica/eletrica/motores-eletricos-componentes-e-suas-aplicacoes.html. Acesso em: 12 abr. 2026.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

JALAN, A. K.; MOHANTY, A. R. Model based fault diagnosis of a rotor–bearing system for misalignment and unbalance under steady-state condition. **Journal of Sound and Vibration**, v. 327, n. 3–5, p. 604–622, 2009.

KAGGLE. **RADAR DATA FOR MACHINE FAULT DETECTION**. [*S.l.: s.n.*], 2026. Disponível em: https://www.kaggle.com/datasets/yunusemreacar1/radar-data-for-machine-fault-detection. Acesso em: 11 set. 2026.

KUNDU, P. Review of rotating machinery elements condition monitoring using acoustic emission signal. **Expert Systems with Applications**, v. 252, p. 124169, 2024.

LUNA, D. A. *et al.* **DETECÇÃO DE FALHAS EM MOTORES TRIFÁSICOS UTILIZANDO DEEP LEARNING NA ANÁLISE DE VIBRAÇÕES**. [*S.l.: s.n.*], 2025. Disponível em: https://doi.org/10.56238/arev7n8-127. Acesso em: 12 abr. 2026.

MOBLEY, R. K. **An Introduction to Predictive Maintenance**. 2. ed. Amsterdam: Butterworth-Heinemann, 2002. 437 p. ISBN 0-7506-7531-4.

NANDI, S.; TOLIYAT, H. A.; LI, X. Condition monitoring and fault diagnosis of electrical motors—a review. **IEEE Transactions on Energy Conversion**, v. 20, n. 4, p. 719–729, 2005.

PENG, C. *et al.* A visual vibration characterization method for intelligent fault diagnosis of rotating machinery. **Mechanical Systems and Signal Processing**, v. 192, p. 110229, 2023.

PEPPERL+FUCHS. **Tipos de sensores de radar**. 2026. Disponível em: https://www.pepperl-fuchs.com/pt-br/support/technologies/industrial-radar-sensors-defying-elements/types-of-radar-sensors-gp28175. Acesso em: 12 set. 2026.

ROCHA, M. B. d. Uso da transformada de fourier para decomposição e análise de sinais ópticos e de rádio, com aplicações em comunicação e espectroscopia. **International Integralize Scientific**, v. 5, n. 46, abr. 2025. ISSN 3085-654X. Disponível em: https://iiscientific.com/artigos/AF3E4F/.

SANTOS, A. **Como funciona um motor industrial?** [*S.l.: s.n.*], 2024. Disponível em: https://loja.br.abb.com/blog/post/como-funciona-motor-industrial?srsltid=AfmBOopWPdjy4Ep857LsN3c35eCFMy8s4eIUIE-jHmNyF2GsLFqF9a8X. Acesso em: 12 abr. 2026.

SERVICE, M. **Conheça os tipos de manutenção para Motores Elétricos**. [*S.l.: s.n.*], 2022. Disponível em: https://mpcservice.com.br/conheca-os-tipos-de-manutencao-para-motores-eletricos/s. Acesso em: 13 abr. 2026.

SU, L. *et al.* Fmcw radar dynamic demodulation: Enabling accurate vibration measurement. **Mechanical Systems and Signal Processing**, v. 252, p. 114224, 2026.

THOMAS, D.; WEISS, B. **Maintenance Costs and Advanced Maintenance Techniques in Manufacturing Machinery: Survey and Analysis**. [*S.l.: s.n.*], 2021. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC9890517/pdf/nihms-1849479.pdf. Acesso em: 11 set. 2026.

TRACTIAN. **O que é um sensor de vibração?** 2023. Disponível em: https://tractian.com/sensor-de-vibracao-industrial. Acesso em: 12 abr. 2026.

TRACTIAN. **Curva PF: como usar na manutenção?** [*S.l.: s.n.*], 2026. Disponível em: https://tractian.com/blog/curva-pf. Acesso em: 11 set. 2026.

APÊNDICES

APÊNDICE A – APÊNDICE(S)

Declaração de uso de INTELIGÊNCIA ARTIFICIAL, cuidados éticos e adequação à LGPD no TCC

MBA em Inteligência Artificial e Big Data – ICMC/USP

Aluno(a): Vítor Fernando Rinaldini

Título do TCC: Aplicação de Técnicas de Aprendizado de Máquina na Predição de Falhas em Motores Elétricos

Declaro que, na elaboração deste Trabalho de Conclusão de Curso:

☐ **Não utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC.**

☒ **Utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC,**

conforme indicado abaixo.

1. **Como utilizei IA**: Marque as opções aplicáveis:

   ☒ Revisão, aprimoramento ou tradução de textos

   ☒ Busca, síntese ou organização de informações e literatura

   ☒ Geração, revisão ou depuração de código

   ☐ Análise, tratamento ou interpretação de dados

   ☐ Apoio à estruturação de ideias, metodologia ou solução

   ☐ Geração ou aprimoramento de imagens, gráficos ou outros conteúdos

   ☐ Outro: _____

Ferramenta utilizadas: OPENAI. *ChatGPT* e GOOGLE. *Gemini*

---

2. **Nível de utilização**
   Marque a opção que melhor representa o uso de IA na elaboração do TCC:

   ☒ **Nível 1 – Apoio pontual**

   Uso em atividades específicas, como revisão de texto, tradução, esclarecimento de dúvidas ou sugestões pontuais.

   ☐ **Nível 2 – Apoio significativo**

   Uso recorrente em algumas etapas, como estruturação de conteúdo, programação, análise de dados ou desenvolvimento da solução.

   ☐ **Nível 3 – Apoio substancial**

   Uso relevante na geração ou desenvolvimento de conteúdos, códigos, análises ou outros elementos que integram o TCC.

3. **Declaração sobre cuidados Éticos e atendimento à LGPD**
   Cuidados éticos: quais foram os procedimentos éticos adotados em pesquisas envolvendo seres humanos, conforme as Normas e Diretrizes Regulamentadoras da Pesquisa Envolvendo Seres Humanos – Resolução C N S N° 466/2012, Norma Operacional 001/2013, Resolução C N S N° 510/2016 e Resolução C N S N° 674/2022 (para pesquisas nacionais). Em trabalhos nos quais pesquisas com seres humanos não foram realizadas, a seção deve ser preenchida com "Não se aplica" ou "Atende à Resolução C N S N° 510/2016".

   ☒ Não se aplica

   ☐ Cuidados adotados: _____

Quando o estudo envolver **coleta, uso ou análise de dados pessoais**, ainda que disponíveis publicamente, as pessoas autoras devem também indicar as medidas adotadas para proteção de dados pessoais, em conformidade com a **Lei Geral de Proteção de Dados Pessoais** – LGPD (Lei N° 13.709/2018), descrevendo, quando pertinente, os cuidados adotados no tratamento desses dados, tais como

procedimentos de anonimização ou pseudonimização e medidas relacionadas ao armazenamento, acesso e segurança das informações. Imagens de pessoas menores de idade ou vulneráveis devem ser suprimidas ou devidamente anonimizadas no texto.

☒ Não se aplica

☐ Medidas adotadas: _____

---

4. **Declaração de responsabilidade**

Declaro que revisei, validei criticamente e assumo a responsabilidade pelos conteúdos produzidos com o auxílio de ferramentas de Inteligência Artificial.

Declaro, ainda, que compreendo plenamente, sou capaz de explicar e defender todo o conteúdo apresentado neste TCC, bem como que observei os princípios éticos e os requisitos de proteção de dados aplicáveis

Data: 22/09/2026

Assinatura do(a) aluno(a): Vitor F. Rinaldini